



Εργασία στο μάθημα Big Data

Πετρούλα Τσιμπίνη ics23085

Ιανουάριος 2025

ΘΕΜΑ 1

Φόρτωση,έλεγχος και καθαρισμός δεδομένων

Στο πρώτο θέμα της εργασίας, πραγματοποιήθηκε η εισαγωγή των δεδομένων στο περιβάλλον του Apache Spark, ο έλεγχος της ποιότητάς τους και έγινε η απαραίτητη προετοιμασία (data cleaning και feature engineering) για τα επόμενα στάδια της ανάλυσης μας στην εργασία.

Προετοιμασία περιβάλλοντος και φόρτωση δεδομένων

Αρχικά, δημιουργήσαμε ένα SparkSession με την ονομασία "TelecomChurnAnalysis". Η φόρτωση του αρχείου telecom_churn_10k.csv έγινε με χρήση του Dataframe API, με τις επιλογές header=True για την αναγνώριση των επικεφαλίδων και inferSchema=True για την αυτόματη αναγνώριση των τύπων δεδομένων των στηλών.

Έλεγχος Σχήματος

Με τη χρήση της μεθόδου printSchema(), επιβεβαιώσαμε τη δομή του dataset.

```
ηρώτες 10 γραμμές του dataframe:
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|CUSTOMER_ID|GENDER|AGE|COUNTRY|TENURE_MONTHS|CONTRACT_TYPE|HAS_INTERNET|HAS_MOBILE|HAS_TV|MONTHLY_CHARGES|TOTAL_CHARGES|NUM_COMPLAINTS|SUPPORT_CALLS|PAYMENT_METHOD|CHURN|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|C000001|Male|68.0|FR|61.0|Month-to-month|0|1|0|17.54|1077.63|0|0|Bank transfer|1.0|
|C000002|Female|65.0|FR|NULL|Month-to-month|1|1|0|50.82|833.94|1|1|Credit card|0.0|
|C000003|Male|36.0|FR|53.0|Two year|1|1|0|34.44|1828.5|0|0|Credit card|0.0|
|C000004|Male|23.0|UK|6.0|Month-to-month|1|1|1|50.66|271.56|1|1|Credit card|0.0|
|C000005|Male|44.0|GR|39.0|Month-to-month|1|1|1|38.82|1519.19|0|0|Credit card|0.0|
|C000006|Female|70.0|GR|25.0|Month-to-month|1|1|1|59.33|1443.72|0|3|Credit card|0.0|
|C000007|Male|65.0|GR|42.0|Month-to-month|0|1|1|47.8|1995.71|0|3|Cash|1.0|
|C000008|Male|NULL|FR|42.0|Two year|1|1|0|29.61|1243.85|0|1|Cash|0.0|
|C000009|Male|76.0|GR|59.0|Month-to-month|0|1|0|23.47|1377.23|0|0|E-banking|1.0|
|C000010|Female|28.0|UK|38.0|One year|1|1|0|49.24|1896.52|0|0|Bank transfer|1.0|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+

only showing top 10 rows
Σχήμα των δεδομένων:
root
|-- CUSTOMER_ID: string (nullable = true)
|-- GENDER: string (nullable = true)
|-- AGE: double (nullable = true)
|-- COUNTRY: string (nullable = true)
|-- TENURE_MONTHS: double (nullable = true)
|-- CONTRACT_TYPE: string (nullable = true)
|-- HAS_INTERNET: integer (nullable = true)
|-- HAS_MOBILE: integer (nullable = true)
|-- HAS_TV: integer (nullable = true)
|-- MONTHLY_CHARGES: double (nullable = true)
|-- TOTAL_CHARGES: double (nullable = true)
|-- NUM_COMPLAINTS: integer (nullable = true)
|-- SUPPORT_CALLS: integer (nullable = true)
|-- PAYMENT_METHOD: string (nullable = true)
|-- CHURN: double (nullable = true)
```

Διαχείριση Ελλιπών Τιμών

Πραγματοποιήθηκε έλεγχος για την ύπαρξη null τιμών σε όλες τις στήλες και ειδικότερα στις στήλες AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES και CHURN.Η ανάλυση έδειξε ελλιπή δεδομένα στις εξής στήλες:

column_name	missing_count
CUSTOMER_ID	0
GENDER	0
AGE	300
COUNTRY	0
TENURE_MONTHS	300
CONTRACT_TYPE	0
HAS_INTERNET	0
HAS_MOBILE	0
HAS_TV	0
MONTHLY_CHARGES	300
TOTAL_CHARGES	300
NUM_COMPLAINTS	0
SUPPORT_CALLS	0
PAYMENT_METHOD	0
CHURN	300

Ερώτηση για σχολιασμό: Εστιάστε ειδικά στα πεδία: AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES, CHURN και σχολιάστε σύντομα ποια από αυτά επηρεάζουν περισσότερο την ανάλυση.

Απάντηση: Το CHURN επηρεάζει περισσότερο την ανάλυση καθώς αποτελεί τη μεταβλητή-στόχο για το μοντέλο πρόβλεψης. Αν λείπει η τιμή εδώ, η εγγραφή δεν μπορεί να χρησιμοποιηθεί για την εκπαίδευση του μοντέλου, καθώς δεν γνωρίζουμε αν ο πελάτης αποχώρησε ή όχι. Τα πεδία TENURE_MONTHS και TOTAL_CHARGES ακολουθούν σε σημασία, καθώς προσδιορίζουν την πιστότητα και την αξία του πελάτη. Ελλιπείς τιμές σε αυτά τα κρίσιμα πεδία εμποδίζουν την ορθή εκπαίδευση του αλγορίθμου και μειώνουν την αξιοπιστία των συμπερασμάτων. Τα πεδία MONTHLY_CHARGES και AGE αν και είναι σημαντικά, η απουσία τους ίσως μπορεί να αναπληρωθεί π.χ. με τη μέση τιμή αλλά το CHURN παραμένει το πιο κρίσιμο για την ακεραιότητα της πρόβλεψης.

Μετά την στρατηγική καθαρισμού αντιμετωπίστηκαν όλες οι null τιμές

--- Δεδομένα μετά τον καθαρισμό (Missing values check) ---

CHURN	AGE	TENURE_MONTHS	MONTHLY_CHARGES	TOTAL_CHARGES
0	0	0	0	0

Μετά τον εντοπισμό των null τιμών, εφαρμόσαμε την εξής στρατηγική καθαρισμού:

Ερώτηση: Ποια στρατηγική επιλέξατε και γιατί;

Απάντηση: Η CHURN αποτελεί τη μεταβλητή-στόχο επομένως οι γραμμές με null τιμές αφαιρέθηκαν (dropna) για να διασφαλιστεί η αξιοπιστία της στα επόμενα βήματα της ανάλυσης και της μοντελοποίησης. Για τα πεδία AGE,

TENURE_MONTHS και MONTHLY_CHARGES, εφαρμόστηκε συμπλήρωση με τη μέση τιμή ώστε να διατηρηθεί το μέγεθος του δείγματος.

Για το πεδίο TOTAL_CHARGES, όπως μας είπατε και στο μάθημα θα μπορούσαμε να βρούμε τον μέσο όρο μηνιαίας χρέωσης και να το πολλαπλασιάσουμε με τα χρόνια που είναι πελάτης, επομένως οι ελλιπείς τιμές υπολογίστηκαν ως το γινόμενο της μηνιαίας χρέωσης επί τη διάρκεια παραμονής του πελάτη ($\text{MONTHLY_CHARGES} * \text{TENURE_MONTHS}$). Αυτή η μέθοδος επιλέχθηκε γιατί είναι πιο ρεαλιστική. Αντί να δώσουμε σε όλους τους πελάτες την ίδια μέση τιμή, υπολογίζουμε το συνολικό κόστος για τον καθένα ξεχωριστά, ανάλογα με το τι πληρώνει τον μήνα και πόσο καιρό είναι στην εταιρεία. Με αυτόν τον τρόπο, τα δεδομένα μας παραμένουν σωστά και αληθινά και το μοντέλο πρόβλεψης που θα φτιάξουμε θα είναι πολύ πιο ακριβές αφού θα βασίζεται σε πραγματικούς υπολογισμούς και όχι σε τυχαίους μέσους όρους.

Βασική Περιγραφική Στατιστική Ανάλυση

Πραγματοποιήθηκε εξαγωγή βασικών στατιστικών μεγεθών (count, mean, stddev, min, max) και μετά ομαδοποιήσαμε τα δεδομένα με βάση τη μεταβλητή CHURN για να συγκρίνουμε τη συμπεριφορά των πελατών:

```
--- Βασικά στατιστικά (Describe) ---
+-----+-----+-----+-----+-----+
|summary|          AGE|    TENURE_MONTHS|  MONTHLY_CHARGES|  TOTAL_CHARGES|
+-----+-----+-----+-----+-----+
|  count|          9700|          9700|          9700|          9700|
|   mean| 51.42650653629523| 36.559855411439315| 36.556964285714315| 1337.0745351492799|
| stddev| 19.247481813671897| 20.466005655823807| 11.127497787046334| 887.3388774541093|
|   min|          18.0|           1.0|           5.0|           0.0|
|   max|          85.0|          72.0|          80.45|        5197.62|
+-----+-----+-----+-----+-----+

Μέσοι όροι ανά κατάσταση Churn (0 = Παραμονή, 1 = Αποχώρηση):
+-----+-----+-----+
|CHURN|      Avg_Tenure|Avg_Monthly_Charges|
+-----+-----+-----+
|  0.0| 38.328541395976266| 36.27477349916856|
|  1.0| 33.56423868839328| 37.03490974729247|
+-----+-----+-----+
```

Ερώτηση για σχολιασμό: Σχολιάστε σε 3–4 προτάσεις τι παρατηρείτε (π.χ. αν οι πελάτες που αποχωρούν έχουν μικρότερο tenure ή/και υψηλότερες χρεώσεις).

Απάντηση: Οι πελάτες που αποχωρούν εμφανίζουν σαφώς μικρότερη διάρκεια παραμονής και ελαφρώς υψηλότερες μηνιαίες χρεώσεις. Η παρατήρηση αυτή υποδηλώνει ότι η μειωμένη δέσμευση και το αυξημένο κόστος επηρεάζουν τον πελάτη και οδηγούν στην αποχώρηση του.

Feature Engineering

Με στόχο την ενίσχυση του dataset, αν και εσείς μας ζητήσατε να δημιουργήσουμε δύο νέα πεδία αποφάσισα να φτιάξω και τα τρία πεδία που μας δώσατε:

1)NUM_SERVICES: Το άθροισμα των υπηρεσιών που χρησιμοποιεί ο πελάτης (HAS_INTERNET + HAS_MOBILE + HAS_TV), υποδεικνύοντας τον βαθμό εξάρτησης από τον πάροχο.

2)AVG_CHARGE_PER_MONTH: Ο μέσος όρος χρέωσης ανά μήνα (TOTAL_CHARGES / TENURE_MONTHS). Για την αποφυγή σφάλματος διαίρεσης με το μηδέν ορίσαμε ως ελάχιστο tenure τον 1 μήνα.

3)IS_LONG_TENURE: Μια δυαδική μεταβλητή που παίρνει την τιμή 1 αν ο πελάτης παραμένει στην εταιρεία για τουλάχιστον 24 μήνες ενώ διαφορετικά παίρνει την τιμή 0.

--- Δείγμα DataFrame με τα νέα πεδία (Feature Engineering) ---

CUSTOMER_ID	TENURE_MONTHS	NUM_SERVICES	IS_LONG_TENURE	AVG_CHARGE_PER_MONTH
C000001	61.0	1	1	17.666065573770492
C000002	36.55985541143951	2	1	22.81026526541081
C000003	53.0	2	1	34.5
C000004	6.0	3	0	45.26
C000005	39.0	3	1	38.953589743589745
C000006	25.0	3	1	57.7488
C000007	42.0	2	1	47.51690476190476
C000008	42.0	2	1	29.615476190476187
C000009	59.0	1	1	23.342881355932203
C000010	38.0	2	1	49.90842105263158

only showing top 10 rows

Μετά την ολοκλήρωση των παραπάνω βημάτων, το dataset είναι καθαρό από ελλιπείς τιμές και εμπλουτισμένο με νέα χαρακτηριστικά

ΘΕΜΑ 2

Ανάλυση Δεδομένων με Spark SQL

Στο δεύτερο μέρος της εργασίας, χρησιμοποιήσαμε **Spark SQL** για την εκτέλεση ερωτημάτων πάνω στο καθαρισμένο σύνολο δεδομένων.

Δημιουργία Προσωρινού Πίνακα

Για να μπορέσουμε να εκτελέσουμε ερωτήματα SQL, θέσαμε το Dataframe df_final ως ένα προσωρινό view με το όνομα churn_view.

Υλοποίηση Ερωτημάτων

Ερώτημα 1-SQL:

2.1. Churn ανά τύπο συμβολαίου

- Υπολογίστε για κάθε CONTRACT_TYPE:
 - συνολικό πλήθος πελατών,
 - πλήθος πελατών με CHURN = 1,
 - ποσοστό churn (%).
- Ταξινομήστε κατά φθίνουσα σειρά ποσοστού churn.

Αποτέλεσμα:

2.1. Churn ανά τύπο συμβολαίου:

CONTRACT_TYPE	Total_Customers	Churn_Count	Churn_Percentage
Month-to-month	5326	2834	53.21
One year	2440	503	20.61
Two year	1934	264	13.65

Ερώτημα 2-SQL:

2.2. Churn ανά πλήθος υπηρεσιών

- Χρησιμοποιήστε το πεδίο NUM_SERVICES (ή αντίστοιχο που δημιουργήσατε) και υπολογίστε:
 - ποσοστό churn για πελάτες με 1, 2 και ≥ 3 υπηρεσίες.

Αποτέλεσμα:

2.2. Churn ανά πλήθος υπηρεσιών (1, 2, ≥ 3):

Service_Group	Total_Customers	Churn_Percentage
0	229	43.23
1	2149	47.98
2	5152	37.38
3+	2170	25.12

Ερώτημα 3-SQL:


2.3. Churn και μηνιαία χρέωση

- Υπολογίστε τη μέση τιμή MONTHLY_CHARGES ξεχωριστά για:
 - CHURN = 0
 - CHURN = 1
- Προαιρετικά, ομαδοποιήστε και ανά CONTRACT_TYPE (π.χ. μέσο MONTHLY_CHARGES για churners/non-churners ανά τύπο συμβολαίου).

Αποτέλεσμα 1(χωρίς το προαιρετικό κομμάτι):

CHURN		average_monthly_charges
0.0		36.27477349916856
1.0		37.03490974729247

..



Εικόνα: Οι πελάτες που αποχώρησαν εμφανίζουν υψηλότερη μέση χρέωση, υποδεικνύοντας ότι το ύψος του λογαριασμού αποτελεί καθοριστικό παράγοντα για το churn. Το γράφημα δείχνει την τιμολογιακή πολιτική κρίσιμη για τη διατήρηση των πελατών και τη μείωση των αποχωρήσεων.

Αποτέλεσμα 2(με το προαιρετικό κομμάτι):

2.3. Μέση Μηνιαία Χρέωση (Monthly Charges) για Churners και Non-Churners:

CONTRACT_TYPE	CHURN	Avg_Monthly_Charges
Month-to-month	0.0	41.23
Month-to-month	1.0	38.5
One year	0.0	35.26
One year	1.0	33.47
Two year	0.0	30.05
Two year	1.0	28.15

Ερώτημα 4-SQL:

3. Γεωγραφική ανάλυση (Top-X περιοχές)

- Υπολογίστε, για κάθε COUNTRY:
 - πλήθος πελατών,
 - ποσοστό churn.
- Διατηρήστε μόνο χώρες με τουλάχιστον **100 πελάτες**.
- Εμφανίστε τις **Top-5** χώρες με το υψηλότερο ποσοστό churn, ταξινομημένες κατά φθίνουσα σειρά.

Αποτέλεσμα:

3. Top-5 Χώρες με το υψηλότερο ποσοστό churn (τουλάχιστον 100 πελάτες):

COUNTRY	Customer_Count	Churn_Percentage
IT	1003	40.78
DE	1198	37.65
GR	3732	37.03
UK	1560	36.15
ES	1050	36.1

Ο σχολιασμός για το παρακάτω έχει προστεθεί στο κελί του Notebook:

4. Έλεγχος των Hints του προβλήματος

Με βάση τα αποτελέσματά σας από τα παραπάνω queries:

- Σχολιάστε αν:
 - οι πελάτες με **Month-to-month** συμβόλαιο έχουν πράγματι υψηλότερο churn σε σχέση με **One year** / **Two year**,
 - οι πελάτες με **πολλαπλές υπηρεσίες** (π.χ. NUM_SERVICES ≥ 3) εμφανίζουν χαμηλότερο churn σε σχέση με όσους έχουν μόνο 1 υπηρεσία,
 - οι πελάτες με υψηλότερες MONTHLY_CHARGES τείνουν να έχουν αυξημένο churn.
- Ο σχολιασμός να γίνει σε **σύντομο κείμενο 8-10 προτάσεων** (Markdown cell στο notebook), όπου θα συνδέετε ρητά τα αριθμητικά αποτελέσματα των ερωτημάτων σας με τα επιχειρησιακά συμπεράσματα.]

ΘΕΜΑ 3

Spark ML Pipeline για Decision Tree

Το Pipeline για Decision Tree στην ουσία κάνει τρία πράγματα:

1. Μετατρέπει το target σε label που καταλαβαίνει το Spark (HighSpender → label),
2. Πακετάρει τα features σε ένα vector (features),
3. Εκπαιδεύει ένα Decision Tree πάνω σε αυτά.

Τα βήματα που ακολουθούμε από την Διάλεξη 7.1 σελ.45

Πρόβλεψη Μηνιαίας Χρέωσης με Decision Tree

Στο τρίτο μέρος της εργασίας υλοποιήθηκε ένα μοντέλο παλινδρόμησης με χρήση του Apache Spark ML, με στόχο την πρόβλεψη της μηνιαίας χρέωσης ενός πελάτη (MONTHLY_CHARGES). Η ανάλυση αυτή έχει επιχειρησιακή σημασία, καθώς επιτρέπει την εκτίμηση του αναμενόμενου λογαριασμού ενός πελάτη με βάση κάποια στοιχεία του και τις υπηρεσίες που χρησιμοποιεί υποστηρίζοντας σενάρια δυναμικής τιμολόγησης και σχεδιασμού προσφορών.

Ορισμός χαρακτηριστικών και μεταβλητής-στόχου

Ως μεταβλητή-στόχος ορίσαμε το πεδίο MONTHLY_CHARGES ενώ ως χαρακτηριστικά χρησιμοποιήθηκαν τα εξής πεδία: AGE, TENURE_MONTHS, NUM_COMPLAINTS, SUPPORT_CALLS, HAS_INTERNET, HAS_MOBILE, HAS_TV, NUM_SERVICES, CONTRACT_TYPE, PAYMENT_METHOD, COUNTRY

Δημιουργήσαμε νέο Dataframe που περιλαμβάνει αποκλειστικά τα παραπάνω χαρακτηριστικά και τη μεταβλητή MONTHLY_CHARGES, αφού είχε προηγηθεί ο καθαρισμός των δεδομένων από ελλιπείς τιμές στο Θέμα 1.

Προεπεξεργασία και δημιουργία Pipeline

Για την κατάλληλη προετοιμασία των δεδομένων, εφαρμόστηκε προεπεξεργασία στα κατηγορικά χαρακτηριστικά με χρήση StringIndexer, ώστε να μετατραπούν σε αριθμητικές αναπαραστάσεις. Στη συνέχεια όλα τα αριθμητικά και κατηγορικά χαρακτηριστικά συνδυάστηκαν σε ένα ενιαίο διάνυσμα εισόδου μέσω VectorAssembler.

Ως αλγόριθμος παλινδρόμησης επιλέχθηκε το DecisionTreeRegressor καθώς είναι εύκολα ερμηνεύσιμος και κατάλληλος για την ανίχνευση μη γραμμικών σχέσεων στα δεδομένα. Όλα τα στάδια (indexers, assembler και μοντέλο) ενσωματώθηκαν σε ένα ενιαίο Spark ML Pipeline, εξασφαλίζοντας καθαρή και αναπαραγώγιμη διαδικασία εκπαίδευσης.

Εκπαίδευση και αξιολόγηση μοντέλου

Το σύνολο δεδομένων χωρίστηκε σε σύνολο εκπαίδευσης και ελέγχου με αναλογία 70% και 30%, χρησιμοποιώντας σταθερό random seed για αναπαραγωγιμότητα των αποτελεσμάτων. Το μοντέλο εκπαιδεύτηκε στο training set και στη συνέχεια παρήγαγε προβλέψεις στο test set.

Για να αξιολογήσουμε την απόδοση του μοντέλου χρησιμοποιήσαμε τις μετρικές:

1)RMSE (Root Mean Squared Error): 8.01

2)R^2 (Coefficient of Determination): 0.50

Σχολιασμός αποτελεσμάτων

Δείγμα Προβλέψεων vs Πραγματικών Τιμών:

MONTHLY_CHARGES	prediction
20.05	20.874141156462592
44.76	35.48900854361217
55.55	47.06706884681583
42.51	39.55160492385313
23.77	42.50082015306125
54.58	39.55160492385313
32.14	29.3736858076564
37.9	30.86769318181819
54.31	47.06706884681583
26.31	30.163351113172542


only showing top 10 rows

Root Mean Squared Error (RMSE) στο test set: 8.01

Coefficient of Determination (R2) στο test set: 0.50

Με βάση τις μετρικές το μοντέλο μπορεί να θεωρηθεί «χονδρικά χρήσιμο» για συγκεκριμένα επιχειρησιακά σενάρια, όπως προσεγγιστικές εκτιμήσεις τιμολόγησης και απλές προσομοιώσεις "what-if". Συγκεκριμένα, η τιμή του RMSE δείχνει ότι, κατά μέσο όρο, η πρόβλεψη της μηνιαίας χρέωσης αποκλίνει περίπου κατά 8€ από την πραγματική τιμή. Ένα σφάλμα των 8€ επιτρέπει τη διεξαγωγή γενικών αναλύσεων και τον σχεδιασμό προσφορών, όμως για τα δεδομένα μεγέθη των λογαριασμών (που κυμαίνονται μεταξύ 20€ και 55€), η απόκλιση αυτή θεωρείται μάλλον υψηλή για την έκδοση ακριβών εξατομικευμένων τιμολογίων. Παράλληλα, η τιμή του $R^2 = 0.50$ υποδηλώνει ότι το μοντέλο εξηγεί περίπου το 50% της διακύμανσης της μηνιαίας χρέωσης, γεγονός που το καθιστά «χονδρικά χρήσιμο» για μια πρώτη εκτίμηση εσόδων. Καθώς μια διαφορά της τάξης των 8€ μπορεί να είναι καθοριστική για την κερδοφορία της εταιρείας ή την ικανοποίηση του πελάτη, το μοντέλο λειτουργεί ως μια καλή αρχή, αλλά για ακριβέστερες προβλέψεις θα απαιτούνταν πιο σύνθετα μοντέλα.

Γραφήματα



Εικόνα: Το γράφημα απεικονίζει τη σχέση μεταξύ των πραγματικών μηνιαίων χρεώσεων (Actual) και των προβλέψεων του Decision Tree μοντέλου (Predicted)

Το γράφημα δημιουργήθηκε βασιζόμενο σε ένα δείγμα των 100 και επιβεβαιώνει όσα αναφέρθηκαν στην ενότητα παραπάνω «Σχολιασμός Αποτελεσμάτων» δηλαδή ότι το μοντέλο συλλαμβάνει τη γενική τάση των δεδομένων ($R^2=0.50$) με τη διασπορά των σημείων γύρω από τη διαγώνιο να αναδεικνύει το σφάλμα των 8.01€. Παρά τη χρησιμότητά του για γενικές προσεγγίσεις, η απόκλιση αυτή κρίνεται επιχειρησιακά υψηλή για ακριβή εξατομικευμένη τιμολόγηση καθώς ένα σφάλμα 8€ επηρεάζει άμεσα την κερδοφορία και την ικανοποίηση του πελάτη.

Περιβάλλον Ανάπτυξης και Εξωτερικές Πηγές

Περιβάλλον Ανάπτυξης

Η ανάπτυξη και εκτέλεση του κώδικα με χρήση των Spark DataFrame API, Spark SQL και Spark ML πραγματοποιήθηκε στο περιβάλλον Google Colab.

RAM:

RAM συστήματος
1.9 / 12.7 GB



Δίσκος
21.2 / 107.7 GB



Εκδόσεις Λογισμικού: Χρησιμοποιήσα γλώσσα προγραμματισμού Python 3.x και την βιβλιοθήκη PySpark 3.x.

Χρήση Τεχνητής Νοημοσύνης (Gemini)

Στην εργασία χρησιμοποίησα το Gemini του Colab ως βοηθητικό εργαλείο στα ακόλουθα σημεία:

Μορφοποίηση αποτελεσμάτων: Το χρησιμοποίησα στις εκτυπώσεις για τη μετατροπή των τελικών αποτελεσμάτων σε ευανάγνωστη και δομημένη μορφή προκειμένου να βελτιώσω την παρουσίαση.

Διόρθωση και βελτιστοποίηση κώδικα: Το χρησιμοποίησα κατά τη εκτέλεση του κώδικα για την αναγνώριση και τη διόρθωση συντακτικών ή λογικών σφαλμάτων που προέκυπταν.

Διατύπωση SQL Queries (Θέμα 2): Το χρησιμοποίησα για βοήθεια στο δεύτερο ερώτημα 2.2 του Spark SQL και σε κάποια σημεία που με δυσκόλεψαν, προκειμένου να υπολογίσω σωστά τα ποσοστά churn.

Υλοποίηση ML Pipeline (Θέμα 3): Το χρησιμοποίησα για συμβουλευτική καθοδήγηση σχετικά με τη δομή του Spark ML Pipeline, για τη σωστή αλληλουχία των StringIndexer, VectorAssembler και DecisionTreeRegressor.