



Τμήμα Εφαρμοσμένης Πληροφορικής

Εργασία στο μάθημα Μηχανές Αναζήτησης και Ανάλυσης Κειμένου

“Ανάλυση Συναισθήματος σε Κριτικές Ταινιών με Χρήση Μοντέλων Naive Bayes και Γλωσσικών Τεχνικών Προεπεξεργασίας”

Πετρούλα Τσιμπίνη ics23085

Ιανουάριος 2026

Πίνακας Περιεχομένων

1. Περιγραφή Pipelines και Επιλογών Προεπεξεργασίας.....	4
1.1 Προεπεξεργασία Κειμένου και Baselines	4
1.2 Κατηγοριοποιητές και Αναπαραστάσεις Εγγράφων	5
1.3 Αποτελέσματα Κατηγοριοποιητών με E1–E3.....	6
1.4 Αναπαράσταση Word2Vec (E4).....	7
2. Γλωσσικές Τεχνικές	8
2.1 Διαχείριση Άρνησης.....	8
2.2 Στάθμιση με POS	8
2.3 Στάθμιση βάση θέσης πρότασης.....	9
2.4 Word2Vec.....	9
2.5 Αποτελέσματα Γλωσσικών Τεχνικών	9
2.5.1 Multinomial Naive Bayes και TF	10
2.5.2 Multinomial Naive Bayes με TF-IDF	12
2.5.3 Bernoulli Naive Bayes με Δυναμική Αναπαράσταση	14
2.5.4 Boolean (Binarized) Multinomial Naive Bayes με Δυναμική Αναπαράσταση ..	16
2.5.5 Multinomial Naive Bayes με Word2Vec embeddings+mean pooling	18
3. Σύγκριση με RapidMiner.....	19
3.1 Ρύθμιση Πειραματικής Διαδικασίας	19
3.2 Αποτελέσματα RapidMiner	19
3.3 Συγκριτική Ανάλυση.....	23
4. Συμπεράσματα	25

Πίνακας Εικόνων

Εικόνα 1.1: Αποτελέσματα αξιολόγησης και ανάδειξη των επικρατέστερων baselines για τον κάθε συνδυασμό.....	6
Εικόνα 1.2: Αποτελέσματα αξιολόγησης και ανάδειξη του επικρατέστερου baseline για τον Multinomial Naive Bayes μαζί με Word2vec.....	7
Εικόνα 2.1: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με αναπαράσταση Term Frequency για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών).....	10
Εικόνα 2.2: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με αναπαράσταση TF-IDF για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)....	12
Εικόνα 2.3: Αποτελέσματα επιδόσεων του Bernoulli Naive Bayes με Δυαδική αναπαράσταση για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)....	14
Εικόνα 2.4: Αποτελέσματα επιδόσεων του Boolean (Binarized) Multinomial Naive Bayes με Δυαδική αναπαράσταση για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών).....	16
Εικόνα 2.5: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με Word2Vec embeddings+mean pooling ,για ένα από τα σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation).....	18
Εικόνα 3.1: Αποτελέσματα RapidMiner πρώτου συνδυασμού.....	19
Εικόνα 3.2: Αποτελέσματα RapidMiner δεύτερου συνδυασμού.....	20
Εικόνα 3.3: Αποτελέσματα RapidMiner τρίτου συνδυασμού.....	21
Εικόνα 3.4: Αποτελέσματα RapidMiner τέταρτου συνδυασμού.....	22

1. Περιγραφή Pipelines και Επιλογών Προεπεξεργασίας

Στο Μέρος Α της εργασίας εξετάσαμε το πρόβλημα της κατηγοριοποίησης συναισθήματος πάνω σε ένα σύνολο δεδομένων που αφορούν σε κριτικές ταινιών, όπου κάθε έγγραφο ανήκει σε μία από τις δύο κατηγορίες είτε θετικό είτε αρνητικό. Χρησιμοποιήσαμε το σύνολο δεδομένων που μας παρέχεται `polarity_dataset_v2.0`, το οποίο περιλαμβάνει 1000 θετικές και 1000 αρνητικές κριτικές.

Στόχος του μέρους Α είναι η υλοποίηση και σύγκριση διαφορετικών παραλλαγών του Naive Bayes σε συνδυασμό με διαφορετικές αναπαραστάσεις εγγράφων και διαφορετικά στάδια προεπεξεργασίας, ώστε να επιλεγεί το καταλληλότερο baseline για κάθε συνδυασμό κατηγοριοποιητή και αναπαράστασης.

Οι 5 συνδυασμοί είναι οι εξής:

- 1) Multinomial Naive Bayes και πλήθος εμφανίσεων
- 2) Multinomial Naive Bayes και TF-IDF
- 3) Multinomial Naive Bayes και Word2Vec embeddings+mean pooling
- 4) Bernoulli Naive Bayes και Διαδική αναπαράσταση
- 5) Boolean (Binarized) Multinomial Naive Bayes και Διαδική αναπαράσταση

1.1 Προεπεξεργασία Κειμένου και Baselines

Ακολουθώντας την οδηγία της εκφώνησης και όσων μας είπατε στην διάλεξη, δοκιμάσαμε διαφορετικούς λογικούς συνδυασμούς σταδίων προεπεξεργασίας χωρίς να εξετάσουμε όλους τους δυνατούς. Συγκεκριμένα, υλοποιήσαμε δύο βασικές ροές προεπεξεργασίας οι οποίες εφαρμόστηκαν σε όλους τους συνδυασμούς..

Επιλέξαμε ως πρώτο baseline τον συνδυασμό Lowercasing, Tokenization και Αφαίρεση Stopwords γιατί αποτελεί μία βάση για κάθε NLP. Η μετατροπή σε πεζά και ο τεμαχισμός σε tokens μειώνουν τον θόρυβο ενώ η αφαίρεση των stopwords επιτρέπει στον κατηγοριοποιητή Naive Bayes να εστιάσει σε λέξεις με υψηλή πληροφοριακή αξία για το συναίσθημα.

Στο Baseline 2, προσθέσαμε το στάδιο του Stemming για να αντιμετωπίσουμε το πρόβλημα της πολυμορφίας των λέξεων. Με την αναγωγή των λέξεων στη ρίζα τους, μειώνεται η διαστασιμότητα του διανύσματος χαρακτηριστικών και ομαδοποιούνται σημασιολογικά συγγενείς όροι.

Η σύγκριση μεταξύ των δύο παρουσιάζει ενδιαφέρον καθώς το stemming μπορεί μερικές φορές να είναι επιθετικό και να αφαιρέσει καταλήξεις που έχουν συναισθηματική φόρτιση επηρεάζοντας αρνητικά τα μοντέλα `tf-idf` και `word2vec`.

1.2 Κατηγοριοποιητές και Αναπαραστάσεις Εγγράφων

Όπως αναφέραμε και προηγουμένως, υλοποιήσαμε και συγκρίναμε τους παρακάτω συνδυασμούς:

1)K1: Multinomial Naive Bayes

E2: Πλήθος εμφανίσεων

E3: TF-IDF

E4: Word2Vec embeddings+mean pooling

2)K2: Bernoulli Naive Bayes

E1: Δυαδική αναπαράσταση

3)K3: Boolean Multinomial Naive Bayes

E1: Δυαδική αναπαράσταση

Για κάθε συνδυασμό, αξιολογήσαμε και τα δύο baselines προεπεξεργασίας και επιλέξαμε εκείνο που μεγιστοποιεί την μετρική macro F1-score.

Η αποτίμηση έγινε με 5-fold stratified cross-validation ώστε να διατηρείται η αναλογία θετικών και αρνητικών κειμένων σε κάθε fold και επιπλέον μετρήσαμε τα ακόλουθα:

- 1)Accuracy
- 2)Precision (macro)
- 3)Recall (macro)
- 4)F1-score (macro)
- 5)Confusion matrix

Για κάθε fold, για την αποφυγή data leakage πραγματοποιήσαμε την διαδικασία vectorization μόνο στο σύνολο εκπαίδευσης του εκάστοτε fold. Στη συνέχεια, το σύνολο ελέγχου το μετασχηματίσαμε με βάση τις παραμέτρους που προέκυψαν μόνο από το training set. Έτσι, διασφαλίσουμε ότι καμία πληροφορία από το test set δεν διέρρευσε στο μοντέλο κατά τη διάρκεια της εκπαίδευσης.

1.3 Αποτελέσματα Κατηγοριοποιητών με E1–E3

Αφού εκτελέσαμε όλα τα παραπάνω προέκυψαν τα εξής αποτελέσματα:

MNB_TF Best baseline: stemming Accuracy: 0.8060 Precision: 0.8064 Recall: 0.8060 F1: 0.8059 Confusion matrix: [[816 184] [204 796]]	BNB_Binary Best baseline: no_stemming Accuracy: 0.7880 Precision: 0.8021 Recall: 0.7880 F1: 0.7854 Confusion matrix: [[896 104] [320 680]]
MNB_TFIDF Best baseline: no_stemming Accuracy: 0.8105 Precision: 0.8129 Recall: 0.8105 F1: 0.8101 Confusion matrix: [[852 148] [231 769]]	Boolean_MNB Best baseline: stemming Accuracy: 0.8225 Precision: 0.8229 Recall: 0.8225 F1: 0.8225 Confusion matrix: [[833 167] [188 812]]

Εικόνα 1.1: Αποτελέσματα αξιολόγησης και ανάδειξη των επικρατέστερων baselines για τον κάθε συνδυασμό.

Multinomial NB με Πλήθος Εμφανίσεων (E2): Το baseline με **stemming** επικράτησε με F1: 0.8059. Η επιτυχία του stemming εδώ οφείλεται στο ότι ο Multinomial NB βασίζεται στις συχνότητες των λέξεων. Ομαδοποιώντας διαφορετικούς τύπους της ίδιας λέξης στην ίδια ρίζα, το μοντέλο αποκτά ισχυρότερη στατιστική βάση για τις λέξεις-κλειδιά που προσδιορίζουν το συναίσθημα.

Multinomial NB με TF-IDF (E3): Εδώ το **no-stemming** απέδωσε καλύτερα με F1: 0.8101. Στην αναπαράσταση TF-IDF, η σπανιότητα μιας λέξης παίζει καθοριστικό ρόλο. Το stemming φέρνει τις λέξεις στη ρίζα τους και αυτο μπορεί να εξαφανίσει λεπτές γλωσσικές διαφορές που το TF-IDF χρησιμοποιεί για να δώσει βάρος σε σημαντικούς όρους.

Bernoulli NB με Δυαδική Αναπαράσταση (E1): Και εδώ καλύτερη επίδοση σημείωσε **no-stemming** με F1: 0.7854. Ο Bernoulli NB εξετάζει μόνο την παρουσία ή απουσία μιας λέξης. Τα αποτελέσματα μας έδειξαν ότι η διατήρηση των λέξεων

στην αρχική τους μορφή επιτρέπει στο μοντέλο να εκμεταλλευτεί την πληροφορία που φέρουν οι διαφορετικές μορφές των λέξεων.

Boolean Multinomial NB (E1): Αποτελεί το κορυφαίο μοντέλο του Μέρους Α με χρήση **stemming** με F1: 0.8225. Η κυριαρχία του συγκεκριμένου συνδυασμού επιβεβαιώνει ότι στην ανάλυση συναισθήματος η πληροφορία για το αν μια λέξη υπάρχει στο κείμενο είναι συχνά πιο κρίσιμη από το πόσες φορές εμφανίζεται.

Τα αποτελέσματα δείχνουν ότι δεν υπάρχει μία ενιαία προεπεξεργασία που να είναι βέλτιστη για όλους τους συνδυασμούς, γεγονός που συμφωνεί με τη θεωρητική συμπεριφορά των διαφορετικών παραλλαγών του Naive Bayes.

1.4 Αναπαράσταση Word2Vec (E4)

Για την υλοποίηση του Word2vec, χρησιμοποιήσαμε τον MinMaxScaler, ώστε να μετατρέψουμε τις αρχικές τιμές των embeddings (που περιλαμβάνουν αρνητικούς αριθμούς) στο διάστημα [0, 1]. Η μετατροπή αυτή αποτελεί προϋπόθεση για τη λειτουργία του Multinomial NB, ο οποίος βασίζεται στον υπολογισμό πιθανοτήτων με θετικές τιμές. Επιπλέον, κάθε έγγραφο το αναπαραστήσαμε με mean pooling δηλαδή ως τον μέσο όρο των embeddings των λέξεων που περιέχει. Τέλος, εκπαιδεύσαμε το μοντέλο Word2vec μόνο στα δεδομένα του training fold, ώστε να αποφευχθεί data leakage όπως προείπαμε.

Τα αποτελέσματα που παρουσιάστηκαν είναι τα εξής:

```
E4: Word2Vec + Mean Pooling + MultinomialNB
Best baseline: no_stemming
Accuracy: 0.5745
Precision: 0.5748
Recall: 0.5745
F1: 0.5742
Confusion matrix:
[[587 413]
 [438 562]]
```

Εικόνα 1.2: Αποτελέσματα αξιολόγησης και ανάδειξη του επικρατέστερου baseline για τον Multinomial Naive Bayes μαζί με Word2vec.

Στην περίπτωση της αναπαράστασης **Word2vec (E4)**, το baseline no-stemming υπερίσχυσε με F1-score ίσο με 0.5742. Παρατηρούμε ότι η μέθοδος αυτή έχει την χαμηλότερη απόδοση σε σύγκριση με τις bag-of-words αναπαραστάσεις το οποίο θεωρείται λογικό. Και αυτό γιατί, τα word embeddings τα εκπαιδεύσαμε σε ένα περιορισμένο σύνολο δεδομένων μόνο στο training fold, γεγονός που περιορίζει την

ικανότητα του μοντέλου να βρει σύνθετες σημασιολογικές σχέσεις. Επιπλέον, ο Multinomial Naive Bayes δεν είναι ιδανικός κατηγοριοποιητής για συνεχή και πυκνά διανύσματα.

2. Γλωσσικές Τεχνικές

Στο Μέρος Β μελετήσαμε την επίδραση των τριών ακολούθων γλωσσικών τεχνικών. Της διαχείρισης της άρνησης, της στάθμισης με POS και της στάθμισης με βάση της θέσης της πρότασης πάνω στους κατηγοριοποιητές Naive Bayes, χρησιμοποιώντας ως baseline την προεπεξεργασία που αποδείξαμε ως βέλτιστη για κάθε συνδυασμό κατηγοριοποιητή-αναπαράστασης στο Μέρος Α.

2.1 Διαχείριση Άρνησης

Οι λέξεις άρνησης (π.χ not, never, no) ανιχνεύονται στο κείμενο και όλα τα tokens που ακολουθούν μέχρι το επόμενο σημείο στίξης λαμβάνουν το πρόθεμα NOT_. Με τον τρόπο αυτό, φράσεις όπως not good μετατρέπονται σε NOT_good, επιτρέποντας στο μοντέλο να διακρίνει τη σημασιολογική αλλαγή. Η τεχνική αυτή στον κώδικα μου εφαρμόζεται στο επίπεδο των tokens πριν τη διανυσματική αναπαράσταση.

2.2 Στάθμιση με POS

Μετά τη δημιουργία του διανύσματος χαρακτηριστικών, εφαρμόσαμε στάθμιση με βάρος 2 σε λέξεις που αναγνωρίζονται ως:

1)Επίθετα (JJ, JJR, JJS)

2)Επιρρήματα (RB, RBR, RBS)

και βάρος 1 σε όλες τις υπόλοιπες.

Όπως μας αναφέρατε στο μάθημα αλλά και στην εκφώνηση την στάθμιση δεν την εφαρμόζουμε στα ίδια τα tokens, αλλά στην διανυσματική αναπαράσταση. Για τις δυαδικές αναπαραστάσεις (Bernoulli NB και Boolean MNB), η στάθμιση δεν έχει επίδραση καθώς η αναπαράσταση μετατρέπεται σε 0/1 και τα βάρη εξαλείφονται.

2.3 Στάθμιση βάση θέσης πρότασης

Τα tokens που εμφανίζονται στην πρώτη ή στην τελευταία πρόταση του κειμένου λαμβάνουν βάρος 2, ενώ τα υπόλοιπα βάρος 1. Και εδώ την στάθμιση την εφαρμόσαμε στο διανυσματικό χώρο και όχι στα ίδια τα tokens.

2.4 Word2Vec

Στην περίπτωση των Word2Vec embeddings, εφαρμόσαμε μόνο την τεχνική της διαχείρισης άρνησης καθώς αυτή γίνεται σε επίπεδο λεξιλογίου πριν την παραγωγή των διανυσμάτων. Τις τεχνικές στάθμισης με POS και στάθμισης με βάση θέσης πρότασης δεν τις χρησιμοποιήσαμε επειδή βασίζονται σε τροποποίηση βαρών σε αναπαραστάσεις τύπου bag-of-words. Στο Word2vec με mean pooling, οι λέξεις συνδυάζονται σε ένα ενιαίο διάνυσμα, με αποτέλεσμα να χάνεται η πληροφορία σε επίπεδο token.

2.5 Αποτελέσματα Γλωσσικών Τεχνικών

Αρχικά, τις γλωσσικές τεχνικές τις εκτελέσαμε για κάθε έναν από τους πέντε συνδυασμούς κατηγοριοποιητή–αναπαράστασης και χρησιμοποιήσαμε την ροή προεπεξεργασίας (με ή χωρίς stemming) που αναδείχθηκε ως το βέλτιστο baseline για τον κάθε συνδυασμό στο Μέρος Α.

Από το μέρος Α είχαν προκύψει τα εξής βέλτιστα baseline για κάθε συνδυασμό:

- 1) Στο Multinomial Naive Bayes και πλήθος εμφανίσεων επικράτησε το stemming baseline
- 2) Στο Multinomial Naive Bayes και TF-IDF επικράτησε το no-stemming baseline
- 3) Στο Multinomial Naive Bayes και Word2Vec embeddings+mean pooling επικράτησε το no-stemming baseline
- 4) Στο Bernoulli Naive Bayes και Δυαδική αναπαράσταση επικράτησε το no-stemming baseline
- 5) Στο Boolean (Binarized) Multinomial Naive Bayes και Δυαδική αναπαράσταση επικράτησε το stemming baseline

Στη συνέχεια, για κάθε συνδυασμό, εκτελέστηκαν πέντε διαφορετικά σενάρια αξιολόγησης, προκειμένου να απομονωθεί η επίδραση κάθε τεχνικής:

1. **Baseline:** Η αρχική βέλτιστη απόδοση χωρίς επιπλέον γλωσσικές παρεμβάσεις. Σχεδόν ίδια με τα αποτελέσματα του Μέρους Α.
2. **Baseline + Διαχείριση Άρνησης:** Εφαρμογή του προθέματος NOT_ στα tokens.
3. **Baseline + Στάθμιση με POS:** Διπλασιασμός του βάρους στα επίθετα και επιρρήματα εντός του διανυσματικού χώρου.
4. **Baseline + Στάθμιση Θέσης:** Διπλασιασμός του βάρους στα tokens της πρώτης και τελευταίας πρότασης.
5. **Baseline + Όλα μαζί:** Ταυτόχρονη εφαρμογή και των τριών τεχνικών.

Πραγματοποιήσαμε εκ νέου **5-fold stratified cross-validation**, διασφαλίζοντας ότι οι συγκρίσεις είναι δίκαιες και έγκυρες.

2.5.1 Multinomial Naive Bayes και TF

```
===== MNB_TF =====
```

Scenario: Baseline

Accuracy: 0.8025

Precision: 0.8030

Recall: 0.8025

F1: 0.8024

Confusion matrix:

```
[[812 188]
```

```
[207 793]]
```

Scenario: Baseline + Negation

Accuracy: 0.8040

Precision: 0.8043

Recall: 0.8040

F1: 0.8040

Confusion matrix:

```
[[810 190]
```

```
[202 798]]
```

Scenario: Baseline + POS

Accuracy: 0.5015

Precision: 0.4504

Recall: 0.5015

F1: 0.3366

Confusion matrix:

```
[[201 799]
```

```
[198 802]]
```

Scenario: Baseline + Sentence

Accuracy: 0.7970

Precision: 0.7979

Recall: 0.7970

F1: 0.7969

Confusion matrix:

```
[[810 190]
```

```
[216 784]]
```

Scenario: Baseline + All

Accuracy: 0.5020

Precision: 0.5505

Recall: 0.5020

F1: 0.3377

Confusion matrix:

```
[[202 798]
```

```
[198 802]]
```

Εικόνα 2.1: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με αναπαράσταση Term Frequency για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)

1. Σενάριο Baseline και Διαχείριση Άρνησης

Παρατηρήσαμε μια μικρή αλλά σταθερή βελτίωση. Το F1-Score ανέβηκε από **0.8024** (baseline) σε **0.8040**. Η βελτίωση αυτή δείχνει ότι η άρνηση είναι σημαντικός παράγοντας στις κριτικές ταινιών. Ωστόσο, η μικρή αύξηση υποδηλώνει ότι ο Naive

Bayes, λόγω του μεγάλου λεξιλογίου κατάφερνε ήδη να εντοπίζει ένα μέρος του αρνητικού συναισθήματος μέσω άλλων λέξεων που συνυπάρχουν στις αρνητικές κριτικές.

2. Σενάριο Baseline και στάθμιση POS

Σε αυτήν την περίπτωση παρουσιάστηκε μία μεγάλη πτώση. Η απόδοση του συνδυασμού είναι κακή, με το F1-Score να πέφτει από το **0.8024** στο **0.3366**. Η χειροκίνητη παρέμβαση μας για διπλασιασμό του βάρους των επιθέτων και επιρρημάτων λειτούργησε αρνητικά για τον Multinomial Naive Bayes. Ο αλγόριθμος βασίζεται στις πιθανότητες εμφάνισης. Διπλασιάζοντας κάποιες συχνότητες, αλλοιώσαμε τη στατιστική κατανομή των δεδομένων. Στην ουσία, τα βάρη POS υποβάθμισαν την υπόλοιπη πληροφορία του κειμένου, καθιστώντας τον MNB μη ικανό να διακρίνει τις κλάσεις.

3. Σενάριο Baseline και Στάθμιση με βάρη βάση της θέσης της πρότασης

Το F1-Score διαμορφώθηκε στο **0.7969**, τιμή μικρότερη από αυτήν του Baseline. Φαίνεται πως στις συγκεκριμένες κριτικές ταινιών, το συναίσθημα είναι διάσπαρτο σε όλο το κείμενο και όχι συγκεντρωμένο μόνο στα άκρα. Η ενίσχυση των άκρων λειτούργησε ως θόρυβος παρά ως χρήσιμη πληροφορία.

4. Σενάριο Baseline και Όλα Μαζί

Η αρνητική επίδραση του POS weighting κυριάρχησε, με αποτέλεσμα η συνολική απόδοση να παραμείνει πολύ χαμηλή **F1: 0.3377**. Παρά τη θετική συμβολή της άρνησης, η μείωση που προκάλεσαν τα βάρη POS δεν επέτρεψε στο μοντέλο να ανακάμψει.

Συμπερασματική Σύγκριση με το Μέρος A

Συγκρίνοντας το βέλτιστο αποτέλεσμα του Μέρους A (**F1: 0.8059**) με το baseline του Μέρους B (**F1: 0.8024**), βλέπουμε ότι οι δύο μετρικές είναι πολύ κοντά, με τις μικρές διαφορές να οφείλονται στην πιο σύνθετη προεπεξεργασία που κάναμε στο Μέρος B για την υποστήριξη των POS και της στάθμισης με βάρη βάση της θέσης της πρότασης.

2.5.2 Multinomial Naive Bayes με TF-IDF

===== MNB_TFIDF =====

Scenario: Baseline

Accuracy: 0.8105

Precision: 0.8129

Recall: 0.8105

F1: 0.8101

Confusion matrix:

[[852 148]

[231 769]]

Scenario: Baseline + Negation

Accuracy: 0.8055

Precision: 0.8073

Recall: 0.8055

F1: 0.8052

Confusion matrix:

[[841 159]

[230 770]]

Scenario: Baseline + Sentence

Accuracy: 0.8015

Precision: 0.8037

Recall: 0.8015

F1: 0.8011

Confusion matrix:

[[838 162]

[235 765]]

Scenario: Baseline + POS

Accuracy: 0.5015

Precision: 0.4504

Recall: 0.5015

F1: 0.3366

Confusion matrix:

[[201 799]

[198 802]]

Scenario: Baseline + All

Accuracy: 0.5015

Precision: 0.4504

Recall: 0.5015

F1: 0.3366

Confusion matrix:

[[201 799]

[198 802]]

Εικόνα 2.2: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με αναπαράσταση TF-IDF για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)

1. Σενάριο Baseline και Διαχείριση Άρνησης

Το F1-Score είναι ίσο με **0.8052** παρουσιάζοντας μια μείωση σε σχέση με το baseline του Μέρους Β (F1=**0.8101**). Ενώ στο απλό TF η άρνηση βοήθησε, στο TF-IDF παρατηρούμε ότι δεν προσφέρει το ίδιο πλεονέκτημα. Αυτό συμβαίνει γιατί το TF-IDF δίνει χαμηλό βάρος σε λέξεις που εμφανίζονται πολύ συχνά σε πολλά έγγραφα. Οι αρνητικές λέξεις είναι πολύ συχνές και η μετατροπή τους ίσως

δημιούργησε ένα πολύ αραιό λεξιλόγιο με χαμηλά βάρη TF-IDF, που δεν βοήθησε τον κατηγοριοποιητή να διακρίνει καλύτερα τις κλάσεις.

2. Σενάριο Baseline και στάθμιση POS

Όπως και στο TF έτσι και εδώ η απόδοση έπεσε στο **0.3366** (F1-score). Η αποτυχία εδώ είναι ακόμα πιο έντονη, διότι το TF-IDF βασίζεται στην συχνότητα του όρου και στην αντίστροφη συχνότητα εγγράφου. Η παρέμβαση μας με τον διπλασιασμό του βάρους των επιθέτων και επιρρημάτων ακύρωσε την στάθμιση του TF-IDF. Το μοντέλο μας ουσιαστικά έχασε την ικανότητα να αξιολογεί τη σπανιότητα των λέξεων.

3. Σενάριο Baseline και Στάθμιση με βάρη βάση της θέσης της πρότασης

Το F1-Score έχει χαμηλότερη τιμή= **0.8011** από **0.8101**. Η στάθμιση των άκρων λειτούργησε αρνητικά. Φαίνεται ότι στον TF-IDF κατηγοριοποιητή, η ενίσχυση συγκεκριμένων θέσεων στο κείμενο εισάγει μεροληψία και κάνει το μοντέλο να δίνει σημασία σε λέξεις λόγω της θέσης τους και όχι λόγω της πληροφοριακής τους αξίας, η οποία είναι η ουσία του TF-IDF.

4. Σενάριο και Όλα Μαζί

Η απόδοση παρέμεινε στο **0.3366**. Η επίδραση του POS weighting είναι καταλυτική και εκμηδενίζει οποιαδήποτε άλλη τεχνική.

Συγκριτική Σύνοψη για τον TF-IDF

Συγκρίνοντας το **Μέρος Α (F1: 0.8101)** με το baseline του **Μέρους Β (F1: 0.8101)**, παρατηρούμε ότι έχουν ακριβώς τις ίδιες σταθερές τιμές. Ωστόσο, είναι φανερό ότι για τον συνδυασμό MNB + TF-IDF, οι πρόσθετες γλωσσικές τεχνικές (Negation, POS, Position) δεν προσέφεραν βελτίωση.

2.5.3 Bernoulli Naive Bayes με Διαδική Αναπαράσταση

===== BNB_Binary =====

Scenario: Baseline

Accuracy: 0.7825

Precision: 0.7933

Recall: 0.7825

F1: 0.7804

Confusion matrix:

[[878 122]

[313 687]]

Scenario: Baseline + Sentence

Scenario: Baseline + Negation

Accuracy: 0.7825

Accuracy: 0.7820

Precision: 0.7933

Precision: 0.7939

Recall: 0.7825

Recall: 0.7820

F1: 0.7804

F1: 0.7798

Confusion matrix:

Confusion matrix:

[[878 122]

[[882 118]

[313 687]]

[318 682]]

Scenario: Baseline + POS

Scenario: Baseline + All

Accuracy: 0.7825

Accuracy: 0.7820

Precision: 0.7933

Precision: 0.7939

Recall: 0.7825

Recall: 0.7820

F1: 0.7804

F1: 0.7798

Confusion matrix:

Confusion matrix:

[[878 122]

[[882 118]

[313 687]]

[318 682]]

Εικόνα 2.3: Αποτελέσματα επιδόσεων του Bernoulli Naive Bayes με Διαδική αναπαράσταση για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)

1. Σενάριο Baseline και Διαχείριση Άρνησης

Το F1-Score παρέμεινε σχεδόν σταθερό, έπεσε πολύ λίγο από το **0.7804** (baseline) στο **0.7798**. Στον BNB, η προσθήκη της άρνησης αυξάνει τον αριθμό των μοναδικών χαρακτηριστικών. Επειδή όμως ο BNB τιμωρεί την απουσία λέξεων εξίσου με την παρουσία τους, η δημιουργία πολλών νέων αρνητικών tokens φαίνεται να εισάγει περισσότερο θόρυβο παρά χρήσιμη πληροφορία, οδηγώντας σε αυτή την μικρή μείωση.

2. Σενάριο Baseline και Στάθμιση POS και Θέση Πρότασης

Οι τιμές Accuracy, Precision, Recall και F1 παρέμειναν ακριβώς οι ίδιες με το Baseline (**0.7804**). Η στάθμιση με POS ή με βάση τη θέση της πρότασης περιλαμβάνει τον πολλαπλασιασμό της εμφάνισης μιας λέξης με ένα βάρος. Ωστόσο, στην δυαδική αναπαράσταση, οποιαδήποτε τιμή μεγαλύτερη του μηδενός μετατρέπεται αμέσως πάλι σε 1. Συνεπώς, η πληροφορία του βάρους χάνεται τελείως κατά τη μετατροπή των δεδομένων σε 0/1 και το μοντέλο BNB καταλήγει να εκπαιδεύεται σε παρόμοια δεδομένα με το Baseline.

3. Σενάριο και Όλα Μαζί

Το F1-Score διαμορφώθηκε στο **0.7798**. Όπως ήταν αναμενόμενο, το τελικό αποτέλεσμα καθορίστηκε αποκλειστικά από την τεχνική της άρνησης, αφού οι άλλες δύο τεχνικές στάθμισης δεν έχουν καμία επίδραση στη δυαδική μορφή των δεδομένων του Bernoulli.

Συγκριτική Σύνοψη με το Μέρος A

Συγκρίνοντας το **Μέρος A (F1: 0.7854)** με το baseline του **Μέρους B (F1: 0.7804)**, παρατηρούμε μια μικρή μείωση της τάξης του **0.005**. Η διαφορά αυτή επιβεβαιώνει ότι ο BNB είναι ευαίσθητος στον τρόπο με τον οποίο γίνεται το tokenization.

2.5.4 Boolean (Binarized) Multinomial Naive Bayes με Διαδική Αναπαράσταση

===== Boolean_MNB =====

Scenario: Baseline

Accuracy: 0.8220

Precision: 0.8226

Recall: 0.8220

F1: 0.8219

Confusion matrix:

[[828 172]

[184 816]]

Scenario: Baseline + Negation

Accuracy: 0.8235

Precision: 0.8238

Recall: 0.8235

F1: 0.8235

Confusion matrix:

[[825 175]

[178 822]]

Scenario: Baseline + Sentence

Accuracy: 0.8220

Precision: 0.8226

Recall: 0.8220

F1: 0.8219

Confusion matrix:

[[828 172]

[184 816]]

Scenario: Baseline + POS

Accuracy: 0.8220

Precision: 0.8226

Recall: 0.8220

F1: 0.8219

Confusion matrix:

[[828 172]

[184 816]]

Scenario: Baseline + All

Accuracy: 0.8235

Precision: 0.8238

Recall: 0.8235

F1: 0.8235

Confusion matrix:

[[825 175]

[178 822]]

Εικόνα 2.4: Αποτελέσματα επιδόσεων του Boolean (Binarized) Multinomial Naive Bayes με Διαδική αναπαράσταση για τα πέντε σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation, POS Weighting, Sentence Position Weighting και συνδυασμός αυτών)

1. Σενάριο Baseline και Διαχείριση Άρνησης

Το F1-Score σημείωσε αύξηση φτάνοντας στο **0.8235** από το **0.8219**. Στον Boolean MNB, η διαχείριση της άρνησης λειτούργησε θετικά. Η μετατροπή των tokens δημιούργησε νέα χαρακτηριστικά που φέρουν ισχυρή πληροφορία συναισθήματος. Επειδή το μοντέλο είναι Boolean, η εμφάνιση έστω και μιας αρνητικής λέξης αρκεί για να αυξήσει την πιθανότητα της σωστής κλάσης, χωρίς να επηρεάζεται από τη συχνότητα.

2. Σενάριο Baseline + Στάθμιση POS και Θέση Πρότασης

Όπως και στον Bernoulli, οι τιμές παραμένουν ακριβώς οι ίδιες με το baseline=0.8219. Η εξήγηση είναι ίδια με αυτή που δώσαμε στον Bernoulli NB, η δυαδική φύση της αναπαράστασης εξαλείφει οποιοδήποτε βάρος εφαρμόζεται στα tokens.

3. Σενάριο και Όλα Μαζί

Το F1-Score είναι ίσο με 0.8235. Το αποτέλεσμα ταυτίζεται με αυτό της Διαχείρισης Άρνησης, επιβεβαιώνοντας ότι η μόνη τεχνική που κατάφερε να βελτιώσει την απόδοση ήταν η άρνηση.

Συγκριτική Σύνοψη με το Μέρος A

Συγκρίνοντας το Μέρος A (F1: 0.8225) με το baseline του Μέρους B (F1: 0.8219), παρατηρούμε μια εξαιρετικά μικρή απόκλιση για τους ίδιους λόγους που αναφέραμε παραπάνω.

Συμπέρασμα: Ο Boolean MNB όπως βλέπουμε έχει την πιο υψηλή απόδοση και καταφέρνει να επωφελείται από γλωσσικές προσθήκες όπως η άρνηση αλλά και αρκετά στιβαρός ώστε να μην καταρρέει από λανθασμένες στατιστικές σταθμίσεις.

Πίνακας 2.1: Συγκεντρωτικά F1-Score γλωσσικών τεχνικών

	MNB + TF	MNB+ TF-IDF	BNB + Δυαδική	Boolean+Δυαδική
Baseline	0.8024	0.8101	0.7804	0.8219
Baseline+Άρνηση	0.8040	0.8052	0.7798	0.8235
Baseline+POS	0.3366	0.3366	0.7804	0.8219
Baseline+Πρόταση	0.7969	0.8011	0.7804	0.8219
Baseline+Όλα	0.3377	0.3366	0.7798	0.8235

2.5.5 Multinomial Naive Bayes με Word2Vec embeddings+mean pooling

E4 (Part B): Word2Vec + Mean Pooling + MNB + Negation

Accuracy: 0.563

Precision: 0.5632011187393929

Recall: 0.563

F1: 0.562643743645745

Confusion matrix:

[[575 425]

[449 551]]

Εικόνα 2.5: Αποτελέσματα επιδόσεων του Multinomial Naive Bayes με Word2Vec embeddings+mean pooling ,για ένα από τα σενάρια γλωσσικής προεπεξεργασίας (Baseline, Negation)

Ο λόγος για τον οποίο εφαρμόσαμε μόνο την άρνηση στον συνδυασμό Multinomial Naive Bayes με Word2Vec embeddings+mean pooling τον αναφέραμε στην ενότητα 2.4 και υπάρχει και ως σχόλιο στον κώδικα μου.

Η χρήση Word2Vec σε συνδυασμό με τον Multinomial Naive Bayes αποτελεί μια ιδιαίτερη περίπτωση καθώς ο Multinomial Naive Bayes συνήθως αναμένει διακριτές μετρήσεις και όχι συνεχή διανύσματα.

1. Σενάριο Baseline και Διαχείριση Άρνησης

Το F1-Score έπεσε από **0.5742** (baseline μέρος A) σε **0.5626** (baseline μέρος B). Η διαχείριση της άρνησης φαίνεται να δυσκολεύει το Word2Vec. Αυτό συμβαίνει διότι το Word2Vec βασίζεται σε ένα συγκεκριμένο λεξιλόγιο που έχει μάθει κατά την εκπαίδευσή του. Όταν μετατρέπουμε μια λέξη σε "NOT_good", αυτή η νέα λέξη πιθανότατα δεν υπάρχει στο λεξιλόγιο του Word2Vec με αποτέλεσμα να αγνοείται ή να αντικαθίσταται από ένα μηδενικό διάνυσμα. Έτσι, χάνεται η σημασιολογική πληροφορία της αρχικής λέξης οδηγώντας σε μείωση της απόδοσης.

Συνολική Αξιολόγηση Word2Vec

Η χαμηλή απόδοση οφείλεται στον συνδυασμό του Word2Vec με τον Multinomial NB. Ο MNB απαιτεί μη αρνητικές τιμές και συνήθως αέριες συχνότητες. Παρόλο που τα embeddings κανονικοποιήθηκαν για να είναι μη αρνητικά, η απώλεια της πληροφορίας της συχνότητας και η ασυμβατότητα του Naive Bayes με τα πυκνά διανύσματα εμποδίζουν τον συνδυασμό να φτάσει τις επιδόσεις των bag-of-words μοντέλων.

3. Σύγκριση με RapidMiner

Στο τελευταίο μέρος της εργασίας, πραγματοποιήσαμε την σύγκριση των αποτελεσμάτων ανάμεσα σε αυτά του μέρους A και του RapidMiner .

3.1 Ρύθμιση Πειραματικής Διαδικασίας

Σας έχω παραθέσει τα αρχεία .rmp στα οποία έχουμε υλοποιήσει τα βήματα για τα pipeline και τα διαφορετικά στάδια επεξεργασίας (baselines) που δημιουργήθηκαν. Η ροή είναι η εξής:

1. Tokenize
2. Transform Cases
3. Filter Stopwords (English)
4. Stemming (Porter): Όπου απαιτούνταν από το baseline
5. Vectorization: Ρύθμιση σε Binary, Term Frequencies ή TF-IDF
6. Validation: 5 fold Cross Validation

Για την επιλογή της βέλτιστης ροής προεπεξεργασίας σε κάθε συνδυασμό κατηγοριοποιητή-αναπαράστασης χρησιμοποιήθηκε ως κύρια μετρική το **macro-average F1-score**. Η συγκεκριμένη μετρική είναι κατάλληλη, καθώς αποτελεί τον αρμονικό μέσο του precision και του recall προσφέροντας μια ισορροπημένη αξιολόγηση. Επιπλέον, η macro-average δίνει ίσο βάρος και στις δύο κλάσεις (θετική και αρνητική), καθιστώντας την αξιολόγηση αξιόπιστη και ανεξάρτητη από την κατανομή των δεδομένων.

3.2 Αποτελέσματα RapidMiner

Αφού εκτελέσαμε ξεχωριστά για κάθε έναν από τους συνδυασμούς κατηγοριοποιητή-προεπεξεργασίας και επικρατέστερο baseline από το μέρος A, προέκυψαν οι παρακάτω confusion matrixes:

1) Multinomial Naïve bayes με tf-idf: Επικράτησε το no-stemming baseline (Μέρος α)

accuracy: 66.75% +/- 3.52% (micro average: 66.75%)

	true positive	true negative	class precision
pred. positive	671	336	66.63%
pred. negative	329	664	66.87%
class recall	67.10%	66.40%	

Εικόνα 3.1: Αποτελέσματα RapidMiner πρώτου συνδυασμού.

weighted_mean_recall: 66.75% +/- 3.52% (micro average: 66.75%), weights: 1, 1

weighted_mean_precision: 66.79% +/- 3.54% (micro average: 66.75%), weights: 1, 1

Προχωρούμε στον υπολογισμό των μετρικών Macro Average Precision, Macro Average Recall και Macro Average F1, προκειμένου να μπορέσουμε να συγκρίνουμε με τα αποτελέσματα του μέρους Α.

Κλάση Positive

Precision(positive)= $TP/TP+FP = 671/671+336=671/1007=0.6663$

Recall(positive)= $TP/TP+FN = 671/671+329=671/1000=0.671$

Κλάση Negative

Precision(negative)= $TN/TN+FN=664/664+329=664/993=0.6687$

Recall(negative)= $TN/TN+FP=664/664+336=664/1000=0.6640$

Υπολογισμός Macro Averages

Macro Precision=(0.6663 + 0.6687) /2=0.6675

Macro Recall=(0.671 + 0.6640) /2=0.6675

Macro F1=2* (0.6675*0.6675/0.6675+0.6675)=0.6675

2)Multinomial naive bayes με πληθος εμφανισεων: Επικράτησε το stemming baseline (Μέρος α)

accuracy: 66.05% +/- 3.84% (micro average: 66.05%)

	true positive	true negative	class precision
pred. positive	690	369	65.16%
pred. negative	310	631	67.06%
class recall	69.00%	63.10%	

Εικόνα 3.2: Αποτελέσματα RapidMiner δεύτερου συνδυασμού.

weighted_mean_recall: 66.05% +/- 3.84% (micro average: 66.05%), weights: 1, 1

weighted_mean_precision: 66.13% +/- 3.86% (micro average: 66.11%), weights: 1, 1

Προχωρούμε στον υπολογισμό των μετρικών Macro Average Precision, Macro Average Recall και Macro Average F1, προκειμένου να μπορέσουμε να συγκρίνουμε με τα αποτελέσματα του μέρους A.

Κλάση Positive

$$\text{Precision(positive)} = \text{TP} / (\text{TP} + \text{FP}) = 690 / (690 + 369) = 690 / 1059 = 0.6516$$

$$\text{Recall(positive)} = \text{TP} / (\text{TP} + \text{FN}) = 690 / (690 + 310) = 690 / 1000 = 0.690$$

Κλάση Negative

$$\text{Precision(negative)} = \text{TN} / (\text{TN} + \text{FP}) = 631 / (631 + 310) = 631 / 941 = 0.6706$$

$$\text{Recall(negative)} = \text{TN} / (\text{TN} + \text{FN}) = 631 / (631 + 369) = 631 / 1000 = 0.6310$$

Υπολογισμός Macro Averages

$$\text{Macro Precision} = (0.6516 + 0.6706) / 2 = 0.6611$$

$$\text{Macro Recall} = (0.690 + 0.6310) / 2 = 0.6605$$

$$\text{Macro F1} = 2 * (0.6611 * 0.6605 / (0.6611 + 0.6605)) = 0.6608$$

3) Bernoulli Naive Bayes με δυαδική αναπαράσταση: Επικράτησε το no-stemming baseline (Μέρος α)

accuracy: 67.20% +/- 1.98% (micro average: 67.20%)

	true positive	true negative	class precision
pred. positive	704	360	66.17%
pred. negative	296	640	68.38%
class recall	70.40%	64.00%	

Εικόνα 3.3: Αποτελέσματα RapidMiner τρίτου συνδυασμού.

weighted_mean_recall: 67.20% +/- 1.98% (micro average: 67.20%), weights: 1, 1

weighted_mean_precision: 67.28% +/- 1.99% (micro average: 67.27%), weights: 1, 1

Προχωρούμε στον υπολογισμό των μετρικών Macro Average Precision, Macro Average Recall και Macro Average F1, προκειμένου να μπορέσουμε να συγκρίνουμε με τα αποτελέσματα του μέρους A.

Κλάση Positive

$$\text{Precision(positive)} = TP/TP+FP = 704/704+360 = 704/1064 = 0.6617$$

$$\text{Recall(positive)} = TP/TP+FN = 704/704+296 = 704/1000 = 0.704$$

Κλάση Negative

$$\text{Precision(negative)} = TN/TN+FP = 640/640+296 = 640/936 = 0.6838$$

$$\text{Recall(negative)} = TN/TN+FP = 640/640+360 = 640/1000 = 0.6400$$

Υπολογισμός Macro Averages

$$\text{Macro Precision} = (0.6617 + 0.6838) / 2 = 0.6727$$

$$\text{Macro Recall} = (0.704 + 0.6400) / 2 = 0.6720$$

$$\text{Macro F1} = 2 * (0.6727 * 0.6720 / (0.6727 + 0.6720)) = 0.6723$$

4) Boolean (Binarized) Multinomial Naive Bayes με δυαδική αναπαράσταση: Επικράτησε το stemming baseline (Μέρος α)

accuracy: 67.05% +/- 2.42% (micro average: 67.05%)

	true positive	true negative	class precision
pred. positive	666	325	67.20%
pred. negative	334	675	66.90%
class recall	66.60%	67.50%	

Εικόνα 3.4: Αποτελέσματα RapidMiner τέταρτου συνδυασμού.

weighted_mean_recall: 67.05% +/- 2.42% (micro average: 67.05%), weights: 1, 1

weighted_mean_precision: 67.08% +/- 2.43% (micro average: 67.05%), weights: 1, 1

Προχωρούμε στον υπολογισμό των μετρικών Macro Average Precision, Macro Average Recall και Macro Average F1, προκειμένου να μπορέσουμε να συγκρίνουμε με τα αποτελέσματα του μέρους Α.

Κλάση Positive

$$\text{Precision(positive)} = TP/TP+FP = 666/666+325 = 666/991 = 0.672$$

$$\text{Recall(positive)} = TP/TP+FN = 666/666+334 = 666/1000 = 0.666$$

Κλάση Negative

$Precision(negative) = TN / (TN + FN) = 675 / (675 + 334) = 675 / 1009 = 0.669$

$Recall(negative) = TN / (TN + FP) = 675 / (675 + 325) = 675 / 1000 = 0.675$

Υπολογισμός Macro Averages

Macro Precision = $(0.672 + 0.669) / 2 = 0.6705$

Macro Recall = $(0.666 + 0.675) / 2 = 0.6705$

Macro F1 = $2 * (0.6705 * 0.6705 / (0.6705 + 0.6705)) = 0.6705$

Πίνακας 3.1: Συγκεντρωτικά Αποτελέσματα των F1-Score στο RapidMiner

	F1-ΜΕΡΟΣ Γ	F1-ΜΕΡΟΣ Α
MNB με TF	0.6608	0.8059
MNB με TF-IDF	0.6675	0.8101
BNB με δυαδικό	0.6723	0.7854
Boolean MNB με δυαδικό	0.6705	0.8225

3.3 Συγκριτική Ανάλυση

Η σύγκριση ανέδειξε μια σταθερή και σημαντική απόκλιση στις επιδόσεις. Συγκεκριμένα, ο κορυφαίος συνδυασμός στον κωδικά μου (Boolean MNB) πέτυχε F1: 0.8225 ενώ στο RapidMiner απέδωσε F1: 0.6705.

Η διαφορά αυτή που είναι περίπου σταθερή σε όλους τους συνδυασμούς δεν είναι τυχαία και λογικά οφείλεται στα εξής:

1. Αποτελεσματικότητα Καθαρισμού (t.isalpha): Στον κώδικά μου, χρησιμοποίησα την μέθοδο t.isalpha(), η οποία λειτουργεί ως ένα δυνατό φίλτρο που απομακρύνει κάθε token που περιέχει αριθμούς ή σημεία στίξης. Στο RapidMiner, ο Tokenizer διατηρεί περισσότερο θόρυβο δηλαδή δεν αφαιρεί όσα η μέθοδος t.isalpha() και επηρεάζει τις πιθανοτικές υποθέσεις του Naive Bayes. Προσπάθησα να το λύσω προσθέτοντας στο RapidMiner το Filter Tokens(By Content) όπως φαίνεται στην εικόνα, αλλά οι τιμές των αποτελεσμάτων διατηρούνταν ίδιες.



2. Βιβλιοθήκες και Smoothing: Η βιβλιοθήκη Scikit-Learn της Python που χρησιμοποίησα στον κώδικα και το RapidMiner χρησιμοποιούν διαφορετικές εσωτερικές υλοποιήσεις για το Laplace και την κανονικοποίηση των δεδομένων. Η Scikit-Learn αποδεικνύεται πιο αποδοτική για το συγκεκριμένο dataset κριτικών ταινιών.
3. Ποιότητα Λεξικού Stopwords: Η βιβλιοθήκη nltk που χρησιμοποίησα στον κώδικα έχει πιο ενημερωμένη λίστα από την ενσωματωμένη του RapidMiner.
4. Στον κώδικα μου, στο κομμάτι του cross validation έθεσα το `random_state=2026`. Προσπάθησα και στο RapidMiner να κάνω το `use local random seed=2026` μήπως αλλάξουν τα αποτελέσματα, αλλά οι τιμές μετά από τον υπολογισμό του macro average F1 βάση των δεδομένων του confusion matrix ήταν σχεδόν παρόμοιες διατηρώντας τις μεγάλες διαφορές, οπότε δεν το εφάρμοσα.

Cross Validation

☐ *split on batch attribute*

☐ *leave one out*

number of folds

sampling type

stratified sampli... ▼

☐ *use local random seed*

☒ *enable parallel execution*

4. Συμπεράσματα

Στην παρούσα εργασία πραγματοποιήθηκε εκτενής συγκριτική αξιολόγηση παραλλαγών του Naive Bayes σε πρόβλημα ανάλυσης συναισθήματος κειμένου. Στο στάδιο επιλογής baseline, δεν υπήρχε ένα ενιαίο καλύτερο baseline για όλους τους συνδυασμούς και η υψηλότερη απόδοση παρατηρήθηκε στην αναπαράσταση Boolean Multinomial Naive Bayes, γεγονός που δείχνει ότι στο συγκεκριμένο σύνολο δεδομένων η πληροφορία παρουσίας ή απουσίας όρων ήταν πιο διακριτική από τη συχνότητα εμφάνισης κλπ. Από τις γλωσσικές τεχνικές προεπεξεργασίας, η διαχείριση άρνησης είχε μία θετική επίδραση, επιβεβαιώνοντας τη σημασία της σημασιολογικής πληροφορίας στο sentiment analysis. Αντίθετα, η στάθμιση με POS και η στάθμιση βάση θέσης πρότασης είχαν περιορισμένη ή μηδενική συνεισφορά, ιδιαίτερα στις δυαδικές αναπαραστάσεις. Η χαμηλότερη απόδοση της αναπαράστασης Word2Vec είναι αναμενόμενη, καθώς τα embeddings εκπαιδεύτηκαν αποκλειστικά στο συγκεκριμένο corpus και όχι σε μεγάλης κλίμακας προεκπαιδευμένα σύνολα. Τέλος, η σύγκριση με το RapidMiner έδειξε συστηματικά χαμηλότερες επιδόσεις, γεγονός που υποδηλώνει διαφορές στην προεπεξεργασία και στην υλοποίηση των χαρακτηριστικών και όχι στον ίδιο τον αλγόριθμο ταξινόμησης.