



Τμήμα Εφαρμοσμένης Πληροφορικής
Εργασία στο μάθημα Θεωρία Υπολογισμού

***“Αυτόματη Εξαγωγή Πληροφοριών από τη Wikipedia με
Χρήση Κανονικών Εκφράσεων”***

Τσιμπίνη Πετρούλα ics23085

Μάιος 2026

Πίνακας περιεχομένων

1.Εισαγωγή.....	4
2. Μεθοδολογία Υλοποίησης.....	5
2.1 Γενική Περιγραφή	5
2.2 Αρχές Σχεδιασμού και Αιτιολόγηση Υλοποίησης.....	5
3. Ανάλυση Συναρτήσεων και Κανονικών Εκφράσεων.....	6
3.1 Ανάκτηση ιστοσελίδας	6
3.2 Εξαγωγή ονόματος πόλης.....	6
3.3 Εξαγωγή πληθυσμού.....	7
3.4 Εξαγωγή έκτασης	7
3.5 Χώρα ή Περιφέρεια.....	7
3.6 Γεωγραφικές συντεταγμένες	8
3.7 Υψόμετρο	8
3.8 Ζώνη ώρας.....	8
3.9 Θερμοκρασίες.....	9
4. Πειραματικές Δοκιμές και Αποτελέσματα	10
5. Περιπτώσεις Αποτυχίας και Περιορισμοί	16
5.1 Διαφορετική μορφοποίηση της HTML δομής	16
5.2 Απουσία πληροφορίας από τη σελίδα	16
5.3 Διαφορετικά labels ή εναλλακτικές ονομασίες.....	16
5.4 Τοπικότερες ή μικρότερες πόλεις	17
5.5 Γενική Παρατήρηση	17
5.6 Στόχευση στην αγγλική έκδοση της Wikipedia	17
6. Πλεονεκτήματα και Μειονεκτήματα Χρήσης Κανονικών Εκφράσεων	18
7. Συμπεράσματα.....	19
8. Βιβλιογραφία	20

Πίνακας Εικόνων

Εικόνα 1: Διεπαφή του προγράμματος και εισαγωγή url από τον χρήστη 10

Εικόνα 2: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Athens της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 100%)..... 10

Εικόνα 3: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Thessaloniki της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 100%)..... 11

Εικόνα 4: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Madrid της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%)..... 12

Εικόνα 5: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα London της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%)..... 12

Εικόνα 6: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Lisbon της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 80%)..... 13

Εικόνα 7: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Giannitsa της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 60%)..... 14

Εικόνα 8: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Larissa της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 80%)..... 14

Εικόνα 9: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Serres της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%)..... 15

Εικόνα 10: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Axos,Pellias της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 50%)..... 15

1.Εισαγωγή

Η Wikipedia αποτελεί μία από τις πιο διαδεδομένες διαδικτυακές εγκυκλοπαίδειες, παρέχοντας έναν τεράστιο όγκο πληροφοριών για πόλεις, χώρες, πρόσωπα, επιστημονικά θέματα και γενικότερα κάθε είδους γνώση. Οι σελίδες της Wikipedia είναι ημιδομημένες και αυτό γιατί περιλαμβάνουν κείμενο, πίνακες πληροφοριών, υπερσυνδέσμους και μορφοποιημένα δεδομένα.

Η παρούσα εργασία έχει ως κεντρικό αντικείμενο την πρακτική εφαρμογή των κανονικών εκφράσεων ως εργαλείο επεξεργασίας και εξόρυξης πληροφοριών από ημιδομημένα δεδομένα. Πιο συγκεκριμένα, μας ζητήθηκε να αναπτύξουμε ένα πρόγραμμα σε γλώσσα python, το οποίο θα λαμβάνει ως είσοδο έναν σύνδεσμο url σελίδας Wikipedia που αφορά κάποια πόλη από τον χρήστη και θα εξαγάγει οκτώ προκαθορισμένα πεδία πληροφορίας: από το όνομα και τον πληθυσμό της πόλης έως γεωγραφικές συντεταγμένες και θερμοκρασίες χρησιμοποιώντας αποκλειστικά κανονικές εκφράσεις.

Η εργασία εστιάζει στην κατανόηση των δυνατοτήτων αλλά και των περιορισμών που παρουσιάζουν οι κανονικές γλώσσες κατά τη διαχείριση κειμένου που δεν διαθέτει μια απόλυτα αυστηρή δομή. Μέσω της ανάλυσης των αποτελεσμάτων, ελέγχεται πόσο αποδοτική μπορεί να είναι η χρήσης κανονικών εκφράσεων σε περιβάλλοντα όπου η πληροφορία βρίσκεται μέσα σε ετικέτες html, αναδεικνύοντας τις προκλήσεις στη ποικίλη δομή της πληροφορίας.

Η χρήση των κανονικών εκφράσεων αποτελεί βασικό εργαλείο της Θεωρίας Υπολογισμού καθώς συνδέεται άμεσα με τις κανονικές γλώσσες και τα πεπερασμένα αυτόματα. Παράλληλα, χρησιμοποιείται στην αναζήτηση προτύπων μέσα σε ημιδομημένο κείμενο html.

.

2. Μεθοδολογία Υλοποίησης

2.1 Γενική Περιγραφή

Για την υλοποίηση των ζητούμενων της εργασίας αναπτύχθηκε πρόγραμμα σε γλώσσα python, το οποίο χρησιμοποιεί τη βιβλιοθήκη requests για την ανάκτηση του περιεχομένου της ιστοσελίδας και το module re για την αναζήτηση προτύπων μέσα στον πηγαίο κώδικα html.

Η λειτουργία του προγράμματος χωρίζεται σε τέσσερα στάδια:

1. Εισαγωγή του url από τον χρήστη.
2. Λήψη του html περιεχομένου της σελίδας Wikipedia.
3. Εφαρμογή κανονικών εκφράσεων για την εξαγωγή των οκτώ ζητούμενων πληροφοριών που ορίζει η εκφώνηση.
4. Παρουσίαση των αποτελεσμάτων και υπολογισμός ποσοστού επιτυχούς εξαγωγής.

2.2 Αρχές Σχεδιασμού και Αιτιολόγηση Υλοποίησης

Ο κώδικας υλοποιήθηκε τμηματικά όπου για κάθε ζητούμενο πεδίο δημιουργήθηκε ξεχωριστή συνάρτηση όπως `extract_city_name()`, `extract_population()`, `extract_area()`, `extract_country_region()`, `extract_coordinates()`, `extract_elevation()`, `extract_timezone()` και `extract_temperatures()`. Με αυτόν τον τρόπο επιτυγχάνεται καλύτερη οργάνωση. Παράλληλα, η τμηματοποίηση εξασφαλίζει ότι η αποτυχία εξαγωγής ενός πεδίου δεν επηρεάζει τη λειτουργία των υπολοίπων αφού κάθε συνάρτηση λειτουργεί ανεξάρτητα και επιστρέφει "Δεν βρέθηκε" όταν δεν εντοπίσει αποτέλεσμα.

Στα πεδία χρησιμοποιήθηκε ένα σύνολο εναλλακτικών προτύπων και όχι μόνο μία κανονική έκφραση. Η επιλογή αυτή κρίθηκε αναγκαία, επειδή διαφορετικές σελίδες της Wikipedia εμφανίζουν την ίδια πληροφορία με διαφορετική μορφή. Για παράδειγμα, ο πληθυσμός μπορεί να εμφανίζεται ως απλό label Population σε πίνακα html, ως πεδίο wikitext `population_total = 319045` ή ως αριθμός μέσα σε διαφορετική δομή infobox. Για τον λόγο αυτό, η `extract_population()`, για παράδειγμα, εφαρμόζει διαδοχικά τρία διαφορετικά patterns:

```
patterns = [  
    # Μορφή: <td>Population</td><td>325,182</td>  
    r'(?i)Population[^\<]*</t[dh][^\>]*\s*(?:<[^\>]+\s*)*(\d{1,3}(?:,\d{3})+)',  
    # Wikitext: population_total = 325182  
    r'(?i)population[_\s]total\s*=\s*(\d{,})+',  
    # αριθμός με κόμμα κοντά σε "Population"  
    r'(?i)Population.{0,500}?(\\d{1,3}(?:,\\d{3}){1,})',  
]
```

Αντίστοιχα, η `extract_coordinates()` υποστηρίζει τέσσερις διαφορετικές μορφές αναπαράστασης συντεταγμένων στη Wikipedia όπως η decimal μορφή μέσω

, η μορφή με μοίρες/λεπτά/δευτερόλεπτα data-lat/data-lon attributes καθώς και geo-dec span.

Για την εξαγωγή του ονόματος της αρχικά, ελέγχεται ο κύριος τίτλος της σελίδας μέσω του στοιχείου <h1 id="firstHeading">, στη συνέχεια το στοιχείο <title> και τέλος το ίδιο το URL της σελίδας. Έτσι αυξάνεται η πιθανότητα επιτυχούς ανάκτησης, καθώς ακόμα και αν η δομή της σελίδας διαφέρει, το url παραμένει πάντα διαθέσιμο.

Τέλος, οι κανονικές εκφράσεις σχεδιάστηκαν αποκλειστικά για την αγγλική έκδοση της Wikipedia καθώς βασίζονται σε labels όπως Population, Country, Area, Elevation και Time zone κλπ. Η επιλογή αυτή έγινε συνειδητά, ώστε να εξασφαλιστεί μεγαλύτερη ομοιομορφία στη μορφή των δεδομένων και να αυξηθεί η αξιοπιστία της εξαγωγής.

3. Ανάλυση Συναρτήσεων και Κανονικών Εκφράσεων

3.1 Ανάκτηση ιστοσελίδας

Η συνάρτηση fetch_page() χρησιμοποιεί HTTP αίτημα τύπου GET και επιστρέφει τον html κώδικα της σελίδας. Επιπλέον, χρησιμοποιείται User-Agent ώστε η αίτηση να προσομοιάζει κανονικό φυλλομετρητή.

3.2 Εξαγωγή ονόματος πόλης

Η συνάρτηση extract_city_name() προσπαθεί διαδοχικά με τρεις τρόπους εξαγωγής από το στοιχείο <h1 id="firstHeading">, από το <title> και τέλος από το URL της σελίδας. Το κύριο pattern είναι:

```
#Από τον τίτλο της σελίδας
m = re.search(
    r'<h1[^>]*id=["\']firstHeading["\'][^>]*>'
    r'(?<[:<[>]+>)*([<]+)(?<[:<[>]+>)*</h1>',
    html, re.IGNORECASE
)
if m:
    return m.group(1).strip()
```

Το pattern αυτό εντοπίζει το <h1> με το συγκεκριμένο id, αγνοεί εσωτερικές ετικέτες html και κρατά μόνο το καθαρό κείμενο του τίτλου.

3.3 Εξαγωγή πληθυσμού

Στην συνάρτηση `extract_population()` χρησιμοποιούμε περισσότερα από ένα regex patterns, επειδή διαφορετικές σελίδες εμφανίζουν τον πληθυσμό με διαφορετικό τρόπο όπως `population`, `population_total` και αριθμητικές τιμές μέσα σε πίνακες πληροφοριών

```
patterns = [  
    # Μορφή: <td>Population</td><td>325,182</td>  
    r'(?i)Population[^\<]*</t[dh][^\>]*>\s*(?:<[^\>]+\>\s*(\d{1,3}(?:,\d{3})+)',  
    # Wikitext: population total = 325182  
    r'(?i)population[_\s]total\s*=\s*([\d,]+)',  
    # αριθμός με κόμμα κοντά σε "Population"  
    r'(?i)Population.{0,500}?(\d{1,3}(?:,\d{3}){1,})',  
]
```

Το πιο χαρακτηριστικό είναι το πεδίο `population_total` σε μορφή `wikitext` που καταγράφει την αριθμητική τιμή που ακολουθεί. Το `(?i)` εξασφαλίζει ότι η αναζήτηση δεν κάνει διάκριση πεζών-κεφαλαίων.

3.4 Εξαγωγή έκτασης

Η συνάρτηση `extract_area()` αναζητά τιμές με μονάδες μέτρησης όπως:

- `km2`
- `km2`
- `square miles`

```
patterns = [  
    # area_total_km2 ή παρόμοιο στο infobox wikitext  
    r'(?i)area[_\s]total[^\<]{0,200}?([\d,\.\.]+\s*(?:km|sq)',  
    # HTML infobox: "Area" label - > αριθμός + μονάδα  
    r'(?i)(?:Total area|Area)\s*</[^\>]+\>\s*(?:<[^\>]+\>\s*(\d,\.\.\s*(?:km|sq\s*mi)',  
    # Κείμενο: αριθμός + km^2  
    r'([\d,\.\.]+\s*km(?:2|2|&sup2;))',  
    # sq mi  
    r'([\d,\.\.]+\s*sq(?:uare)?\s*mi',  
]
```

Εντοπίζει έναν αριθμό (με κόμματα ή δεκαδικά) που ακολουθείται από `km2` σε οποιαδήποτε από τις συνηθισμένες αναπαραστάσεις του συμβόλου και επιστρέφει την αριθμητική τιμή της έκτασης.

3.5 Χώρα ή Περιφέρεια

Η συνάρτηση `extract_country_region()` προσπαθεί να εντοπίσει τη χώρα μέσω labels όπως `country`, `subdivision_name` και `title attributes` συνδέσμων

```

patterns = [
    # subdivision_name1
    r'(?i)subdivision_name\s*=\s*\[[^\]]+\)',
    #Από το HTML: "Country" row
    r'(?i)(?:Country|Χώρα)\s*<\/(?:th|td)[^>]*>\s*(?:<[>]+>\s*)*([A-ZÀ-Ωa-zà-ω][^<\n]{2,50}?)\s*<\/\s*\n)',
    # data-sort-value ή title σε σύνδεσμο χώρας
    r'(?i)(?:country|nation)[^<]{0,100}<a[^>]*title="([^\"]{2,50})"',
]

```

Το πιο αξιόπιστο pattern είναι το πεδίο `subdivision_name` στο wikitext του infobox και εξάγει το όνομα της χώρας από τον εσωτερικό σύνδεσμο, αποφεύγοντας τυχόν εναλλακτικές ονομασίες που ακολουθούν μετά από |.

3.6 Γεωγραφικές συντεταγμένες

Η συνάρτηση `extract_coordinates()` υποστηρίζει διαφορετικές μορφές αναπαράστασης των συντεταγμένων:

- decimal μορφή (lat;lon)
- μορφή με μοίρες
- data attributes HTML

Η κύρια είναι μέσω του `<span class="geo">`. Εντοπίζει το span με class geo, εξάγει χωριστά το γεωγραφικό πλάτος και μήκος σε δεκαδική μορφή και στη συνέχεια τα μετατρέπει σε (N/S, E/W).

3.7 Υψόμετρο

Η συνάρτηση `extract_elevation()` αναζητά ενδείξεις όπως:

- elevation_m
- Elevation
- metres / meters

```

patterns = [
    r'(?i)elevation[_\s]m\s*=\s*([\d,\.]+)',
    r'(?i)Elevation\s*<\/[>]+>\s*(?:<[>]+>\s*)*([\d,\.]+)\s*(?:m|ft)',
    r'(?i)elevation[^<]{0,100}?([\d,\.]+)\s*m(?:\s|\\(|<|>|<\/>)',
    #από το infobox HTML απευθείας
    r'(?i)Elevation.*?<td[^>]*>\s*([\d,\.]+)\s*m',
    r'(?i)elevation.*?(\d+)\s*metres',
    r'(?i)elevation.*?(\d+)\s*meters',
]

```

Κυρίως εντοπίζει το πεδίο `elevation_m` στο wikitext του infobox και εξάγει την αριθμητική τιμή. Στο αποτέλεσμα προστίθεται αυτόματα η μονάδα "m".

3.8 Ζώνη ώρας

Η συνάρτηση `extract_timezone()` αναγνωρίζει πρότυπα UTC.


```

patterns = [
    #Καλύπτουμε UTC+2, UTC-5, UTC-5, UTC±0
    r'(UTC[+\---±]\d{1,2}(::\d{2})?)',
    r'(?i)Time\s*zone[<]{0,200}(UTC[+\---±]\d{1,2}(::\d{2})?)',
    r'(?i)timezone[<]{0,200}>\s*([A-Z]{2,5}(:[+\-]\d)?)\s*<',
]

```

Καλύπτει όλες τις συνηθισμένες παραλλαγές του συμβόλου διαφοράς και υποστηρίζει τόσο ακέραιες ώρες όπως UTC+2 όσο και υποδιαιρέσεις όπως UTC+05:30.

3.9 Θερμοκρασίες

Η συνάρτηση `extract_temperatures()` εξαγεί μέγιστη, ελάχιστη και μέση θερμοκρασία από κλιματικούς πίνακες.

```

#Μέση Θερμοκρασία
for pat in [
    r'(?i)\bmean[_\s]c\s*=\s*([- \d\.)+)',
    r'(?i)\bavg[_\s]c\s*=\s*([- \d\.)+)',
    r'(?i)Daily\s*mean[<]{0,30}°C.*?<td[>]*>\s*([- \d\.)+)',
    r'(?i)(?:Daily mean|Mean temperature).*?°C.*?<td[>]*>([- \d\.)+)',
]:

```

Τα patterns αυτά εντοπίζουν τα αντίστοιχα πεδία θερμοκρασίας σε βαθμούς κελσίου απευθείας από το wikitext του κλιματικού πίνακα. Ο χαρακτήρας `[- \d\.)]` επιτρέπει και αρνητικές τιμές.

4. Πειραματικές Δοκιμές και Αποτελέσματα

Για την αξιολόγηση του προγράμματος πραγματοποιήθηκαν δοκιμές σε σελίδες διαφορετικών μεγάλων και μικρών πόλεων της Wikipedia. Στην παρούσα ενότητα εμφανίζονται οι δοκιμές και τα screenshots από τα αποτελέσματα των δοκιμών ωστόσο ο σχολιασμός των αποτελεσμάτων ακολουθεί στην επόμενη ενότητα.

Αρχικά, κατά την εκκίνηση του προγράμματος ο χρήστης καλείται να εισάγει τον σύνδεσμο της πόλης που επιθυμεί να αναλύσει, όπως φαίνεται στο παρακάτω στιγμιότυπο:

...

```
Εισάγετε URL Wikipedia πόλης (π.χ https://en.wikipedia.org/wiki/London):  
>ipedia.org/wiki/Thessaloniki
```

Εικόνα 1: Διεπαφή του προγράμματος και εισαγωγή url από τον χρήστη

Στη συνέχεια, παρατίθενται εκτελέσεις του προγράμματος για διαφορετικές πόλεις, προκειμένου να αξιολογηθεί η αποτελεσματικότητα των κανονικών εκφράσεων σε ποικίλες δομές σελίδων της Wikipedia.

Δοκιμή 1 – Athens

url: <https://en.wikipedia.org/wiki/Athens>

Εξήχθησαν επιτυχώς όλα τα πεδία.

...

```
Εισάγετε URL Wikipedia πόλης (π.χ https://en.wikipedia.org/wiki/London):  
>https://en.wikipedia.org/wiki/Athens
```

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Athens>

Success	1. Όνομα πόλης	Athens
Success	2. Πληθυσμός	643,452
Success	3. Έκταση	364.2 km ²
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	37.98417°N, 23.72806°E
Success	6. Υψόμετρο	413 m
Success	7. Ζώνη ώρας	UTC+2
Success	8α. Μέγιστη θερμοκρασία	22.8 °C
Success	8β. Μέση θερμοκρασία	10.2 °C
Success	8γ. Ελάχιστη θερμοκρασία	1.7 °C

Επιτυχής εξαγωγή: 10/10 πεδία (100%)

Εικόνα 2: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Athens της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 100%).

Δοκιμή 2 – Thessaloniki

url: <https://en.wikipedia.org/wiki/Thessaloniki>

Εξήχθησαν επιτυχώς όλα τα πεδία όπως φαίνεται και στην ακόλουθη εικόνα.

...

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/Thessaloniki>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Thessaloniki>

Success	1. Όνομα πόλης	Thessaloniki
Success	2. Πληθυσμός	319,045
Success	3. Έκταση	7.454 km ²
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	40.6403°N, 22.9356°E
Success	6. Υψόμετρο	75 m
Success	7. Ζώνη ώρας	UTC+2
Success	8α. Μέγιστη θερμοκρασία	22.5 °C
Success	8β. Μέση θερμοκρασία	7.0 °C
Success	8γ. Ελάχιστη θερμοκρασία	5.2 °C

Επιτυχής εξαγωγή: 10/10 πεδία (100%)

Εικόνα 3: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Thessaloniki της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 100%).

Δοκιμή 3 – Madrid

url: <https://en.wikipedia.org/wiki/Madrid>

Η δομή της σελίδας επέστρεψε υψηλό ποσοστό επιτυχίας με μόνη εξαίρεση το πεδίο της έκτασης .Η αιτία που πιθανώς αποτυγχάνει αναλύεται στην ενότητα 5.

...

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/Madrid>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Madrid>

Success	1. Όνομα πόλης	Madrid
Success	2. Πληθυσμός	3,477,497
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Spain
Success	5. Συντεταγμένες	40.4169°N, 3.7033°W
Success	6. Υψόμετρο	660 m
Success	7. Ζώνη ώρας	UTC+1
Success	8α. Μέγιστη θερμοκρασία	19.9 °C
Success	8β. Μέση θερμοκρασία	6.5 °C
Success	8γ. Ελάχιστη θερμοκρασία	0.6 °C

Επιτυχής εξαγωγή: 9/10 πεδία (90%)

Εικόνα 4: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Madrid της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%).

Δοκιμή 4 – London

url: <https://en.wikipedia.org/wiki/London>

Η δομή της σελίδας επέστρεψε υψηλό ποσοστό επιτυχίας με μόνη εξαίρεση το πεδίο του υψόμετρου.

...

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/London>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/London>

Success	1. Όνομα πόλης	London
Success	2. Πληθυσμός	14,980
Success	3. Έκταση	611 km ²
Success	4. Χώρα / Περιφέρεια	Londinium
Success	5. Συντεταγμένες	51.50722°N, 0.1275°W
Failed	6. Υψόμετρο	Δεν βρέθηκε
Success	7. Ζώνη ώρας	UTC+00:00
Success	8α. Μέγιστη θερμοκρασία	17.2 °C
Success	8β. Μέση θερμοκρασία	5.6 °C
Success	8γ. Ελάχιστη θερμοκρασία	3.9 °C

Επιτυχής εξαγωγή: 9/10 πεδία (90%)

Εικόνα 5: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα London της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%).

Δοκιμή 5 – Lisbon

url: <https://en.wikipedia.org/wiki/Lisbon>

Η δομή της σελίδας επέστρεψε υψηλό ποσοστό επιτυχίας με μόνη εξαίρεση το πεδίο της έκτασης και το υψόμετρο.

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>)
><https://en.wikipedia.org/wiki/Lisbon>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Lisbon>

Success	1. Όνομα πόλης	Lisbon
Success	2. Πληθυσμός	575,739
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Government of Portugal
Success	5. Συντεταγμένες	38.72528°N, 9.15°W
Failed	6. Υψόμετρο	Δεν βρέθηκε
Success	7. Ζώνη ώρας	UTC±00:00
Success	8α. Μέγιστη θερμοκρασία	22.6 °C
Success	8β. Μέση θερμοκρασία	11.8 °C
Success	8γ. Ελάχιστη θερμοκρασία	0.2 °C

Επιτυχής εξαγωγή: 8/10 πεδία (80%)

Εικόνα 6: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Lisbon της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 80%).

Δοκιμή 6 – Giannitsa

url: <https://en.wikipedia.org/wiki/Giannitsa>

Η δομή της σελίδας επέστρεψε μέτριο ποσοστό επιτυχίας.

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/Giannitsa>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Giannitsa>

Success	1. Όνομα πόλης	Giannitsa
Success	2. Πληθυσμός	32,410
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	40.783°N, 22.4°E
Success	6. Υψόμετρο	7 m
Success	7. Ζώνη ώρας	UTC+2
Failed	8α. Μέγιστη θερμοκρασία	Δεν βρέθηκε
Failed	8β. Μέση θερμοκρασία	Δεν βρέθηκε
Failed	8γ. Ελάχιστη θερμοκρασία	Δεν βρέθηκε

Επιτυχής εξαγωγή: 6/10 πεδία (60%)

Εικόνα 7: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Giannitsa της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 60%).

Δοκιμή 7 – Larissa

url: <https://en.wikipedia.org/wiki/Larissa>

Η δομή της σελίδας επέστρεψε υψηλό ποσοστό επιτυχίας με μόνη εξαίρεση το πεδίο της έκτασης και το υψόμετρο.

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/Larissa>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Larissa>

Success	1. Όνομα πόλης	Larissa
Success	2. Πληθυσμός	164,095
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	39.6417°N, 22.417°E
Failed	6. Υψόμετρο	Δεν βρέθηκε
Success	7. Ζώνη ώρας	UTC+2
Success	8α. Μέγιστη θερμοκρασία	22.8 °C
Success	8β. Μέση θερμοκρασία	5.3 °C
Success	8γ. Ελάχιστη θερμοκρασία	1.4 °C

Επιτυχής εξαγωγή: 8/10 πεδία (80%)

Εικόνα 8: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Larissa της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 80%).

Δοκιμή 8 – Serres

url: <https://en.wikipedia.org/wiki/Serres>

Η δομή της σελίδας επέστρεψε υψηλό ποσοστό επιτυχίας με μόνη εξαίρεση το πεδίο της έκτασης.

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
><https://en.wikipedia.org/wiki/Serres>

WIKIPEDIA CITY INFO EXTRACTOR

URL: <https://en.wikipedia.org/wiki/Serres>

Success	1. Όνομα πόλης	Serres
Success	2. Πληθυσμός	70,703
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	41.083°N, 23.55°E
Success	6. Υψόμετρο	70 m
Success	7. Ζώνη ώρας	UTC+2
Success	8α. Μέγιστη θερμοκρασία	20.5 °C
Success	8β. Μέση θερμοκρασία	5.1 °C
Success	8γ. Ελάχιστη θερμοκρασία	6.8 °C

Επιτυχής εξαγωγή: 9/10 πεδία (90%)

Εικόνα 9: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Serres της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 90%).

Δοκιμή 9 – Axos, Pella

url: https://en.wikipedia.org/wiki/Axos,_Pella

Η δομή της σελίδας επέστρεψε μέτριο ποσοστό επιτυχίας.

Εισάγετε URL Wikipedia πόλης (π.χ <https://en.wikipedia.org/wiki/London>):
>https://en.wikipedia.org/wiki/Axos,_Pella

WIKIPEDIA CITY INFO EXTRACTOR

URL: https://en.wikipedia.org/wiki/Axos,_Pella

Success	1. Όνομα πόλης	Axos, Pella
Success	2. Πληθυσμός	1,055
Failed	3. Έκταση	Δεν βρέθηκε
Success	4. Χώρα / Περιφέρεια	Greece
Success	5. Συντεταγμένες	40.801°N, 22.363°E
Failed	6. Υψόμετρο	Δεν βρέθηκε
Success	7. Ζώνη ώρας	UTC+2
Failed	8α. Μέγιστη θερμοκρασία	Δεν βρέθηκε
Failed	8β. Μέση θερμοκρασία	Δεν βρέθηκε
Failed	8γ. Ελάχιστη θερμοκρασία	Δεν βρέθηκε

Επιτυχής εξαγωγή: 5/10 πεδία (50%)

Εικόνα 10: Αποτελέσματα εξαγωγής δεδομένων από τη σελίδα Axos,Pellas της αγγλόφωνης Wikipedia (ποσοστό επιτυχίας 50%).

5. Περιπτώσεις Αποτυχίας και Περιορισμοί

Κατά την αξιολόγηση των πειραμάτων του προγράμματος που παρουσιάστηκαν στην προηγούμενη ενότητα διαπιστώθηκε ότι η συνολική απόδοση ήταν ικανοποιητική στις περισσότερες περιπτώσεις. Σε μεγάλες και καλά δομημένες σελίδες πόλεων της αγγλόφωνης Wikipedia, όπως η Αθήνα και η Θεσσαλονίκη επιτεύχθηκε πλήρης εξαγωγή όλων των ζητούμενων πεδίων. Αντίστοιχα υψηλά ποσοστά επιτυχίας παρατηρήθηκαν και σε άλλες πόλεις όπως η Μαδρίτη, το Λονδίνο, η Λάρισα και οι Σέρρες. Παρόλα αυτά, σε ορισμένες περιπτώσεις εμφανίστηκαν αποτυχίες εξαγωγής κάποιων πεδίων, γεγονός αναμενόμενο, καθώς δεν απαιτείται το πρόγραμμα να λειτουργεί σωστά για όλες τις σελίδες της Wikipedia.

Οι βασικότεροι λόγοι αποτυχίας ήταν οι εξής:

5.1 Διαφορετική μορφοποίηση της HTML δομής

Οι σελίδες της Wikipedia αν και ακολουθούν κοινή λογική δεν έχουν απολύτως ίδια δομή. Ορισμένα πεδία εμφανίζονται σε διαφορετικές θέσεις ή με διαφορετική σύνταξη με αποτέλεσμα κάποια regex patterns να μην τα αναγνωρίζουν.

Χαρακτηριστικό παράδειγμα που προκύπτει και από τις δοκιμές αποτελεί η έκταση, η οποία δεν εντοπίστηκε σε πόλεις όπως η Μαδρίτη, η Λισαβόνα, η Λάρισα, οι Σέρρες, τα Γιαννιτσία, η Άξος Πέλλας. Η παρατήρηση αυτή δείχνει ότι το συγκεκριμένο πεδίο παρουσιάζει μεγαλύτερη ποικιλία μορφοποίησης σε σχέση με άλλα.

5.2 Απουσία πληροφορίας από τη σελίδα

Σε ορισμένες σελίδες δεν υπήρχαν διαθέσιμα όλα τα ζητούμενα πεδία και πιο συγκεκριμένα τα κλιματικά στοιχεία ή το υψόμετρο. Σε τέτοιες περιπτώσεις, το πρόγραμμα επέστρεφε την ένδειξη «Δεν βρέθηκε». Για παράδειγμα, στα Γιαννιτσία και στην Αξό Πέλλας δεν εντοπίστηκαν θερμοκρασίες.

5.3 Διαφορετικά labels ή εναλλακτικές ονομασίες

Κάποια πεδία μπορεί να εμφανίζονται με διαφορετικές λέξεις-κλειδιά από αυτές που αναζητούνται στις κανονικές εκφράσεις και αυτό από ότι φάνηκε επηρεάζει κυρίως τα πεδία:

- Elevation / Altitude
- Area / Total area / Municipality area

5.4 Τοπικότερες ή μικρότερες πόλεις

Παρατηρήθηκε ότι οι μικρότερες πόλεις ή λιγότερο προβεβλημένες περιοχές διαθέτουν συχνά λιγότερο πλήρη infoboxes και μικρότερη ποσότητα δεδομένων όπως οι περιοχές:

- Γιαννιτσά: 6/10
- Άξος Πέλλας: 5/10

Αντίθετα, μεγάλες πρωτεύουσες και αστικά κέντρα διαθέτουν περισσότερο πλήρεις σελίδες, γεγονός που οδηγεί σε υψηλότερα ποσοστά επιτυχίας.

5.5 Γενική Παρατήρηση

Συνολικά, το πρόγραμμα απέδωσε καλύτερα σε σελίδες μεγάλων πόλεων με οργανωμένο infobox και σαφή παρουσίαση δεδομένων, ενώ εμφάνισε μειωμένη απόδοση σε μικρότερες πόλεις ή σε σελίδες με ελλιπή στοιχεία.

Το πιο συχνό πεδίο αποτυχίας ήταν η έκταση ενώ ακολούθησαν το υψόμετρο και οι θερμοκρασίες. Αντίθετα, πεδία όπως το όνομα πόλης, ο πληθυσμός, η χώρα και οι συντεταγμένες εντοπίστηκαν με ιδιαίτερα υψηλά ποσοστά επιτυχίας.

Η συμπεριφορά αυτή θεωρείται αναμενόμενη και συμβατή με τη φύση των κανονικών εκφράσεων, οι οποίες λειτουργούν αποτελεσματικά όταν η πληροφορία ακολουθεί συγκεκριμένα μοτίβα αλλά δυσκολεύονται όταν η μορφοποίηση διαφοροποιείται σημαντικά.

5.6 Στόχευση στην αγγλική έκδοση της Wikipedia

Το πρόγραμμα αφορά τη δομή των σελίδων της αγγλόφωνης έκδοσης της Wikipedia. Οι κανονικές εκφράσεις που χρησιμοποιούνται αναζητούν λέξεις-κλειδιά όπως Population, Area, Country, Elevation, Time zone και αντίστοιχα labels που εμφανίζονται συνήθως στα αγγλικά infoboxes.

Η επιλογή αυτή έγινε ώστε να εξασφαλιστεί μεγαλύτερη ομοιομορφία στη μορφή των labels και στον τρόπο παρουσίασης των πληροφοριών, γεγονός που διευκολύνει τη χρήση κανονικών εκφράσεων και αυξάνει την αξιοπιστία της εξαγωγής.

6. Πλεονεκτήματα και Μειονεκτήματα Χρήσης Κανονικών Εκφράσεων

Η χρήση κανονικών εκφράσεων για εξαγωγή πληροφορίας από ημιδομημένα δεδομένα, όπως οι σελίδες της Wikipedia, παρουσιάζει σημαντικά πλεονεκτήματα αλλά και μειονεκτήματα.

Πλεονεκτήματα

- Παρέχουν γρήγορη και αποδοτική αναζήτηση προτύπων μέσα σε μεγάλο όγκο κειμένου.
- Επιτρέπουν σχετικά σύντομη υλοποίηση χωρίς την ανάγκη σύνθετων μηχανισμών ανάλυσης.
- Είναι αποτελεσματικές στην ανίχνευση αριθμητικών δεδομένων, μονάδων μέτρησης και σταθερών labels.
- Συνδέονται άμεσα με τις έννοιες των κανονικών γλωσσών και των πεπερασμένων αυτομάτων γεγονός που τις καθιστά ιδιαίτερα σχετικές με το αντικείμενο της Θεωρίας Υπολογισμού.
- Δίνουν τη δυνατότητα γρήγορης προσαρμογής με προσθήκη νέων patterns όταν απαιτείται.

Μειονεκτήματα

- Είναι ευαίσθητες σε αλλαγές της html δομής μιας ιστοσελίδας.
- Η συντήρηση πολλών διαφορετικών patterns γίνεται δυσκολότερη όσο μεγαλώνει ο κώδικας.
- Σύνθετες κανονικές εκφράσεις μειώνουν την αναγνωσιμότητα και δυσκολεύουν τον εντοπισμό λαθών.
- Δεν αποτελούν ιδανικό εργαλείο για πλήρη ανάλυση html δομών.
- Η αποτελεσματικότητά τους εξαρτάται σε μεγάλο βαθμό από την ομοιομορφία της μορφοποίησης των δεδομένων.

7. Συμπεράσματα

Η παρούσα εργασία έδειξε ότι οι κανονικές εκφράσεις μπορούν να αξιοποιηθούν αποτελεσματικά στην εξαγωγή πληροφορίας από ημιδομημένα δεδομένα όπως οι σελίδες της Wikipedia.

Το πρόγραμμα κατάφερε να ανακτήσει και να εντοπίσει σημαντικό ποσοστό των ζητούμενων χαρακτηριστικών για διαφορετικές πόλεις όπως πληθυσμό, γεωγραφικά στοιχεία, ζώνη ώρας και κλιματικά δεδομένα κλπ. Τα αποτελέσματα των δοκιμών έδειξαν υψηλή απόδοση κυρίως σε σελίδες με οργανωμένη δομή και πλήρες infobox.

Παράλληλα, διαπιστώθηκε ότι όσο αυξάνεται η πολυπλοκότητα ή η ανομοιομορφία της δομής των δεδομένων, τόσο εντονότερα εμφανίζονται οι περιορισμοί των κανονικών εκφράσεων. Συνεπώς, οι regex αποτελούν ισχυρό εργαλείο για στοχευμένη αναζήτηση προτύπων χωρίς όμως να αποτελούν καθολική λύση για κάθε μορφή html.

Συνολικά, η εργασία συνέβαλε στην κατανόηση της πρακτικής εφαρμογής των κανονικών γλωσσών και στην εφαρμογή θεωρητικών εννοιών της Θεωρίας Υπολογισμού σε πραγματικό πρόβλημα εξόρυξης πληροφορίας.

8. Βιβλιογραφία

1. Python Software Foundation. Python Documentation - re module.
2. Python Software Foundation. Python Documentation - requests library.
3. Wikipedia.
4. Σημειώσεις μαθήματος Θεωρίας Υπολογισμού.